

ИНТЕЛЛЕКТ ➤

Токенизация, оценка качества LLM

к.ф.-м.н. Тихомиров Михаил Михайлович

старший научный сотрудник
НИВЦ МГУ имени М. В. Ломоносова

Токенизация до subword tokenization



Как можно представить текст для нейронной сети перед векторизацией?

- Символы: ['Б', 'о', 'л', 'ь', 'ш', 'и', 'е', ' ', 'я', 'з', 'ы', 'к', 'о', 'в', 'ы', ...]
 - Семантика единицы минимальна.
 - Длина последовательности = количеству символов.
- Слова: ['Большие', 'языковые', 'модели', 'в', 'вопросно-ответных', ...]
 - Разных слов только на одном языке миллионы.
 - Богатая морфология “ухудшает” ситуацию.
- Леммы: ['большой', 'языковой', 'модель', 'в', 'вопросно-ответный', ...]
 - Основной рабочий вариант раньше,
 - Размеры словаря ~200-500 тыс. слов, остальное UNK.
 - Теряется морфология.

- Компромисс между символами и словами.
- Старт с словаря, состоящего из символов (каждый символ - токен).
- Последовательное **объединение** наиболее частотных пар токенов.
- Больше **нет OOV**, а размер словаря может быть небольшим (например, 32 тыс.)!
- Наиболее популярный на данный **момент**.

Algorithm 1 Learn BPE operations

```
import re, collections

def get_stats(vocab):
    pairs = collections.defaultdict(int)
    for word, freq in vocab.items():
        symbols = word.split()
        for i in range(len(symbols)-1):
            pairs[symbols[i], symbols[i+1]] += freq
    return pairs

def merge_vocab(pair, v_in):
    v_out = {}
    bigram = re.escape(' '.join(pair))
    p = re.compile(r'(?!\S)' + bigram + r'(?!\S)')
    for word in v_in:
        w_out = p.sub(' '.join(pair), word)
        v_out[w_out] = v_in[word]
    return v_out

vocab = {'l o w </w>' : 5, 'l o w e r </w>' : 2,
        'n e w e s t </w>':6, 'w i d e s t </w>':3}
num_merges = 10
for i in range(num_merges):
    pairs = get_stats(vocab)
    best = max(pairs, key=pairs.get)
    vocab = merge_vocab(best, vocab)
    print(best)
```

Unigram



- Подход **сверху-вниз** в отличие от BPE.
- Стартует с **большого словаря**: наиболее частотные слова корпуса + подстроки + все символы.
- Используя **униграмм** языковую модель и текущий словарь токенов, рассчитываются вероятности всех текстовых последовательностей (предложений) корпуса.
- После чего рассчитывается, удаление каких токенов из словаря меньше всего повышает значение лосс функции:

$$P(\mathbf{x}) = \prod_{i=1}^M p(x_i), \quad \mathcal{L} = \sum_{s=1}^{|D|} \log(P(X^{(s)})) = \sum_{s=1}^{|D|} \log\left(\sum_{\mathbf{x} \in S(X^{(s)})} P(\mathbf{x})\right)$$

- 10-20% токенов удаляется, после чего повторение прошлых шагов.

Algorithm 2 Unigram LM (Kudo, 2018)

```
1: Input: set of strings  $D$ , target vocab size  $k$ 
2: procedure UNIGRAMLM( $D, k$ )
3:    $V \leftarrow$  all substrings occurring more than
4:     once in  $D$  (not crossing words)
5:   while  $|V| > k$  do ▷ Prune tokens
6:     Fit unigram LM  $\theta$  to  $D$ 
7:     for  $t \in V$  do ▷ Estimate token 'loss'
8:        $L_t \leftarrow p_\theta(D) - p_{\theta'}(D)$ 
9:       where  $\theta'$  is the LM without token  $t$ 
10:    end for
11:    Remove  $\min(|V| - k, \lfloor \alpha |V| \rfloor)$  of the
12:      tokens  $t$  with highest  $L_t$  from  $V$ ,
13:      where  $\alpha \in [0, 1]$  is a hyperparameter
14:  end while
15:  Fit final unigram LM  $\theta$  to  $D$ 
16:  return  $V, \theta$ 
17: end procedure
```

Unigram vs BPE

- **BPE** проще и **быстрее** строить, меньше нагрузка на RAM.
 - Обучение **Unigram** на корпусе из 40GB текстов занимает **1T RAM**.
- **BPE** интуитивно **понятнее**.
- **Unigram** разбивает текст **ближе к морфологии языка**, чем **BPE**, что особенно заметно на языках с богатой морфологией (например русский).

Method	English (w.r.t. CELEX2)			Japanese (w.r.t. McCab)		
	Precision	Recall	F1	Precision	Recall	F1
BPE	38.6%	12.9%	19.3%	78.6%	69.5%	73.8%
Uni. LM	62.2%	20.1%	30.3%	82.2%	72.8%	77.2%

Table 3: Correspondence of subword boundaries between unsupervised tokenization methods and morphological reference segmentations.

sentencepiece



- Пакет от google для обучения токенизации (BPE/Unigram)
- Результат достаточно просто потом “конвертируется” в huggingface токенизацию
- Особое представление пробелов

```
>>> import sentencepiece as spm
>>> s = spm.SentencePieceProcessor(model_file='spm.model')
>>> for n in range(5):
...     s.encode('New York', out_type=str, enable_sampling=True, alpha=0.1, nbest_size=-1)
...
['_', 'N', 'e', 'w', '_York']
['_', 'New', '_York']
['_', 'New', '_Y', 'o', 'r', 'k']
['_', 'New', '_York']
['_', 'New', '_York']
```

```
[32] list(tokenizer_json['model']['vocab'].items())[250:270] tokenizer_json['model']['merges'][:20]
```

```
[['_<0xF7>', 250),
 ('<0xF8>', 251),
 ('<0xF9>', 252),
 ('<0xFA>', 253),
 ('<0xFB>', 254),
 ('<0xFC>', 255),
 ('<0xFD>', 256),
 ('<0xFE>', 257),
 ('<0xFF>', 258),
 ('_', 259),
 ('_', 260),
 ('_t', 261),
 ('_in', 262),
 ('_en', 263),
 ('_a', 264),
 ('_he', 265),
 ('_on', 266),
 ('_re', 267),
 ('_s', 268),
 ('_en', 269)]
```

```
[['_t', 't'],
 ['i', 'n'],
 ['e', 'r'],
 ['_', 'a'],
 ['h', 'e'],
 ['o', 'n'],
 ['n', 'e'],
 ['_', 's'],
 ['e', 'n'],
 ['a', 't'],
 ['o', 'r'],
 ['_t', 'he'],
 ['_th', 'e'],
 ['_', 'the'],
 ['e', 's'],
 ['_', 'w'],
 ['a', 'n'],
 ['_', 'c'],
 ['i', 's'],
 ['i', 't']]
```

- Библиотека от OpenAI
- Специальное представление токенов в модели
 - Словарь хранится в специальном представлении
 - Мержи происходят тоже в нем

```
list(tokenizer_json['model']['vocab'].items())[130000:130020] [43] tokenizer_json['model']['merges'][:20]
```

```
[('ĭıı', 130000),  
( 'à,kàıIà,²à,ť', 130001),  
( 'ġkullanÄı1', 130002),  
( 'ġtÄ'', 130003),  
( 'ăġ«ăĥiăĥı', 130004),  
( 'ġeıııfıı', 130005),  
( 'ġxġıjxġxġxġ', 130006),  
( 'ġrıÄâ', 130007),  
( 'ġrıÄâng', 130008),  
( 'ġyakÄın', 130009),  
( '0²0$, 130010),  
( 'Ä», 130011),  
( 'xıjxġxııı', 130012),  
( '0²0$0ııĥ', 130013),  
( 'ġ0ıDıġġ', 130014),  
( 'x'', 130015),  
( 'ġ0$0²ıı', 130016),  
( 'ġTâ»kng', 130017),  
( 'ıı0.', 130018),  
( 'Äıııad', 130019)]
```

```
[[ 'ġ', 'ġ'],  
[ 'ġġ', 'ġġ'],  
[ 'ı', 'n'],  
[ 'ġ', 't'],  
[ 'ġġġ', 'ġġġ'],  
[ 'e', 'r'],  
[ 'ġġ', 'ġ'],  
[ 'o', 'n'],  
[ 'ġ', 'a'],  
[ 'r', 'e'],  
[ 'a', 't'],  
[ 's', 't'],  
[ 'e', 'n'],  
[ 'o', 'r'],  
[ 'ġt', 'h'],  
[ 'ġ', 'ġ'],  
[ 'ġ', 'c'],  
[ 'l', 'e'],  
[ 'ġ', 's'],  
[ 'ı', 't']]
```

```
def bytes_to_unicode():
```

```
    """
```

Returns list of utf-8 byte and a mapping to unicode strings. We specifically avoids mapping to whitespace/control characters the bpe code barfs on.

The reversible bpe codes work on unicode strings. This means you need a large # of unicode characters in your vocab if you want to avoid UNKs. When you're at something like a 10B token dataset you end up needing around 5K for decent coverage. This is a significant percentage of your normal, say, 32K bpe vocab. To avoid that, we want lookup tables between utf-8 bytes and unicode strings.

```
    """
```

```
bs = (  
    list(range(ord("!"), ord("~") + 1)) + list(range(ord("¡"), ord("ñ") + 1)) + list(range(ord("ª"), ord("ÿ") + 1))  
)  
cs = bs[:1]  
n = 0  
for b in range(2**8):  
    if b not in bs:  
        bs.append(b)  
        cs.append(2**8 + n)  
        n += 1  
cs = [chr(n) for n in cs]  
return dict(zip(bs, cs))
```

“Особенности” токенизации в современных пакетах



- Токенизатор всегда считает первое слово последовательности “пробельным”.
- Представление для “ Слово” и “\nСлово” отличны.
- Разные id токенов -> разные вектора на вход.

```
tokenizer('Слово', add_special_tokens=False)['input_ids']
[20] ✓ 0.0s
... [1406, 1120, 1175]

tokenizer(' \Слово', add_special_tokens=False)['input_ids']
[17] ✓ 0.0s
... [28705, 1406, 1120, 1175]

tokenizer('\n\n\n', add_special_tokens=False)['input_ids']
[18] ✓ 0.0s
... [28705, 13, 28844, 1120, 1175]

tokenizer.convert_ids_to_tokens([28705, 1406, 28844])
[21] ✓ 0.0s
... ['_', '_C', 'C']
```

Пример словаря токенов в модели GPT



Московский
государственный
университет
имени М.В. Ломоносова

```
"\": 255961,  
"|": 255962,  
"┘": 255963,  
"⊕": 255965,  
"×": 255966,  
"Ⓢ": 255967,  
"[toxicity=0]": 255968,  
"\t\t": 255969,  
"\t\t\t": 255970,  
"\t\t\t\t": 255971,  
"\t\t\t\t\t": 255972,  
"\t\t\t\t\t\t": 255973,  
"\t\t\t\t\t\t\t": 255974,  
"\t\t\t\t\t\t\t\t": 255975,  
"\t\t\t\t\t\t\t\t\t": 255976,  
"\t\t\t\t\t\t\t\t\t\t": 255977,  
"\t\t\t\t\t\t\t\t\t\t\t": 255978,  
"\t\t\t\t\t\t\t\t\t\t\t\t": 255979,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t": 255980,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255981,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255982,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255983,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255984,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255985,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255986,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255987,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255988,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255989,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255990,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255991,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255992,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255993,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255994,  
"\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t\t": 255995,
```

Пример токенизации текста в ChatGPT



Московский
государственный
университет
имени М.В. Ломоносова

Token count

41

Price per prompt

\$0.000041

Большие языковые модели в вопросно-ответных системах: от трансформера до собственного чат бота

```
[61432, 17461, 30480, 1532, 46410, 9136, 4655, 90877, 5173  
6, 71239, 61642, 5927, 5927, 29256, 42057, 13999, 12, 1333  
7, 48074, 44786, 93099, 1506, 10693, 25, 20879, 11047, 3568  
2, 2297, 57719, 91883, 57297, 5524, 14082, 20812, 5372, 399  
00, 17756, 8131, 14391, 13337, 1506]
```

Token count

19

Price per prompt

\$0.000019

Large language models in question-answering systems: from a transformer to your own chat bot

```
[35353, 4221, 4211, 304, 3488, 12, 598, 86, 4776, 6067, 25,  
505, 264, 43678, 311, 701, 1866, 6369, 11164]
```

Разница в токенизации для языков



- Токенизация полностью **зависит от корпуса**, на котором обучалась.
- Если в корпусе было мало какого-нибудь языка, то и слово будет разбиваться на много токенов.
- Чем **больше токенов**, тем **дольше** ее **обработка!**
- В **LLaMa** и других открытых моделях в среднем **2 символа на токен для русского языка**.



- Проблема использования больших языковых моделей для русского языка:
 - Многие модели **мультязычные**, но **качество** разнится в **зависимости от языка**, в основном они ориентированы на английский.



- Проблема использования больших языковых моделей для русского языка:
 - Многие модели **мультязычные**, но **качество** разнится в **зависимости от языка**, в основном они ориентированы на английский.
 - Лучшие **LLM** (Large Language Models) для русского языка **англоязычные**.




- Проблема использования больших языковых моделей для русского языка:
 - Многие модели **мультязычные**, но **качество** разнится в **зависимости от языка**, в основном они ориентированы на английский.
 - Лучшие **LLM** (Large Language Models) для русского языка англоязычные.
 - **Экономическая эффективность** использования LLM, зависит от **токенизации**, а у большинства открытых LLM на русском языке она “слабая”.


Цель - перенос мультязычных LLM на русский язык с заменой токенизации для достижения:

1. Повышения эффективности работы LLM на языке
2. (опционально) Повышение качества работы LLM на языке

Шаг 1: подготовка более подходящей токенизации



Шаг 2: адаптация базовой версии LLM



Результаты адаптации модели LLaMa 7B



	LiDiRus	RCB	PARus	MuSeRC	TERRa	RUSSE	RWSD	DaNetQA	RuCoS	mean
llama7b	0,361	0,462	0,672	0,799	0,860	0,624	0,682	0,866	0,802	0,681
llama7b_rulm_raw	0,392	0,494	0,688	0,805	0,859	0,631	0,669	0,871	0,791	0,689
llama7b_rulm_bpe	0,365	0,509	0,684	0,782	0,844	0,626	0,747	0,824	0,737	0,680
llama7b_rulm_unigram	0,412	0,561	0,732	0,800	0,875	0,660	0,675	0,865	0,756	0,704
llama7b_rulm_unigram_hm	0,387	0,546	0,750	0,815	0,866	0,660	0,740	0,812	0,758	0,704

Сравнение качества моделей на RSG с дообучением

	LiDiRus	RCB	PARus	MuSeRC	TERRa	RUSSE	RWSD	DaNetQA	RuCoS	mean
saiga7b	0,084	0,412	0,528	0,311	0,514	0,484	0,675	0,676	0,319	0,445
saiga7b_rulm_raw	0,025	0,373	0,610	0,310	0,523	0,587	0,584	0,783	0,474	0,474
saiga7b_rulm_bpe	0,149	0,429	0,596	0,344	0,647	0,478	0,636	0,757	0,397	0,493
saiga7b_rulm_unigram	0,194	0,432	0,568	0,313	0,591	0,587	0,630	0,789	0,477	0,509
saiga7b_rulm_unigram_hm	0,198	0,413	0,584	0,349	0,533	0,587	0,578	0,789	0,475	0,501

Сравнение качества инструктивных версий моделей на RSG в zero-shot

Почему недостаточно адаптации базовой версии недостаточно



Московский
государственный
университет
имени М.В. Ломоносова

- Адаптация происходит для **базовых моделей**, не **инструктивных**

Почему недостаточно адаптации базовой версии недостаточно



Московский
государственный
университет
имени М.В. Ломоносова

- Адаптация происходит для базовых моделей, не инструктивных
- Пользователи обычно взаимодействуют именно с инструктивными!

Почему недостаточно адаптации базовой версии недостаточно



Московский
государственный
университет
имени М.В. Ломоносова

- Адаптация происходит для базовых моделей, не инструктивных
- Пользователи обычно взаимодействуют именно с инструктивными!
- **Требуется воспроизводить** процедуру **instruct-tuning** с базы
 - LLaMa-3 обучалась на 10 миллионах инструкций (датасет не опубликован!)
 - Лучшая версия модели mistral openchat-3.5 обучалась на датасете, который также **закрыт**


Шаг 3: Адаптация инструктивных версий (Learned Embeddings Propagation)



Московский
государственный
университет
имени М.В. Ломоносова

Основная идея:

- **Адаптировать** базовую модель
- **Рассчитать проекцию** из эмбедингов исходной базовой в инстракт версию
- **Применить проекцию** на адаптированную базу



Шаг 4: Дообучение после LER (опционально)



- Проекция не точна и модель нужно дополнительно откалибровать

Model	Fine-tuning data	Micro-Avg	DaruMMLU	DaruMERA	DaruSum	DaruCopy (EN)	DaruCopy (RU)
OpenChat 3.5							
Original tokenization	-	0,607	0,543	0,526	0,322	0,999	0,917
	saiga d7	0,611	0,540	0,528	0,325	0,999	0,945
	+copy task	0,615	0,541	0,524	0,324	1,000	0,995
Unigram	-	0,565	0,515	0,519	0,301	0,999	0,651
	saiga d7	0,599	0,532	0,556	0,316	0,999	0,754
	+copy task	0,630	0,530	0,559	0,321	1,000	0,999
Extended	-	0,609	0,535	0,541	0,306	0,999	0,909
	saiga d7	0,616	0,543	0,566	0,319	0,999	0,845
	+copy task	0,632	0,541	0,563	0,321	1,000	0,989
LLaMa-3-8B instruct							
Original tokenization	-	0,610	0,571	0,510	0,322	1,000	0,972
	saiga d7	0,615	0,576	0,512	0,329	1,000	0,983
	+copy task	0,616	0,575	0,513	0,332	1,000	0,995
Extended	-	0,597	0,556	0,501	0,318	0,994	0,921
	self-calibration	0,606	0,552	0,512	0,321	1,000	0,958
	saiga d7	0,614	0,568	0,519	0,338	0,995	0,961
	+copy task	0,618	0,565	0,521	0,339	1,000	0,984
Optimized	-	0,598	0,555	0,500	0,324	0,995	0,928
	self-calibration	0,601	0,550	0,501	0,325	1,000	0,95
	saiga d7	0,611	0,555	0,515	0,336	1,000	0,971
	+copy task	0,617	0,555	0,522	0,339	1,000	0,989

Шаг 4: Дообучение после LER (опционально)



- Проекция не точна и модель нужно дополнительно откалибровать
- Как вариант калибровки - дообучение на русскоязычных инструкциях (с эмбедингами)

Model	Fine-tuning data	Micro-Avg	DaruMMLU	DaruMERA	DaruSum	DaruCopy (EN)	DaruCopy (RU)
OpenChat 3.5							
Original tokenization	-	0,607	0,543	0,526	0,322	0,999	0,917
	saiga d7	0,611	0,540	0,528	0,325	0,999	0,945
	+copy task	0,615	0,541	0,524	0,324	1,000	0,995
Unigram	-	0,565	0,515	0,519	0,301	0,999	0,651
	saiga d7	0,599	0,532	0,556	0,316	0,999	0,754
	+copy task	0,630	0,530	0,559	0,321	1,000	0,999
Extended	-	0,609	0,535	0,541	0,306	0,999	0,909
	saiga d7	0,616	0,543	0,566	0,319	0,999	0,845
	+copy task	0,632	0,541	0,563	0,321	1,000	0,989
LLaMa-3-8B instruct							
Original tokenization	-	0,610	0,571	0,510	0,322	1,000	0,972
	saiga d7	0,615	0,576	0,512	0,329	1,000	0,983
	+copy task	0,616	0,575	0,513	0,332	1,000	0,995
Extended	-	0,597	0,556	0,501	0,318	0,994	0,921
	self-calibration	0,606	0,552	0,512	0,321	1,000	0,958
	saiga d7	0,614	0,568	0,519	0,338	0,995	0,961
	+copy task	0,618	0,565	0,521	0,339	1,000	0,984
Optimized	-	0,598	0,555	0,500	0,324	0,995	0,928
	self-calibration	0,601	0,550	0,501	0,325	1,000	0,95
	saiga d7	0,611	0,555	0,515	0,336	1,000	0,971
	+copy task	0,617	0,555	0,522	0,339	1,000	0,989

Шаг 4: Дообучение после LER (опционально)



- Проекция не точна и модель нужно дополнительно откалибровать
- Как вариант калибровки - дообучение на русскоязычных инструкциях (с эмбедингами)
- Растет качество, падает количество “артефактов”, таких как заикливание или выдуманные слова.

Model	Fine-tuning data	Micro-Avg	DaruMMLU	DaruMERA	DaruSum	DaruCopy (EN)	DaruCopy (RU)
OpenChat 3.5							
Original tokenization	-	0,607	0,543	0,526	0,322	0,999	0,917
	saiga d7	0,611	0,540	0,528	0,325	0,999	0,945
	+copy task	0,615	0,541	0,524	0,324	1,000	0,995
Unigram	-	0,565	0,515	0,519	0,301	0,999	0,651
	saiga d7	0,599	0,532	0,556	0,316	0,999	0,754
	+copy task	0,630	0,530	0,559	0,321	1,000	0,999
Extended	-	0,609	0,535	0,541	0,306	0,999	0,909
	saiga d7	0,616	0,543	0,566	0,319	0,999	0,845
	+copy task	0,632	0,541	0,563	0,321	1,000	0,989
LLaMa-3-8B instruct							
Original tokenization	-	0,610	0,571	0,510	0,322	1,000	0,972
	saiga d7	0,615	0,576	0,512	0,329	1,000	0,983
	+copy task	0,616	0,575	0,513	0,332	1,000	0,995
Extended	-	0,597	0,556	0,501	0,318	0,994	0,921
	self-calibration	0,606	0,552	0,512	0,321	1,000	0,958
	saiga d7	0,614	0,568	0,519	0,338	0,995	0,961
	+copy task	0,618	0,565	0,521	0,339	1,000	0,984
Optimized	-	0,598	0,555	0,500	0,324	0,995	0,928
	self-calibration	0,601	0,550	0,501	0,325	1,000	0,95
	saiga d7	0,611	0,555	0,515	0,336	1,000	0,971
	+copy task	0,617	0,555	0,522	0,339	1,000	0,989

Пример адаптации знаний



Что означает фраза "моя хата с краю"?

OpenChat-3.5

Фраза "моя хата с краю" не имеет прямого значения на русском языке. Однако, если рассматривать её в контексте украинского языка, то "хата" означает "изба" или "хутор", а "краю" означает "краю" или "границе". Таким образом, можно предположить, что эта фраза означает "моя изба на границе" или "моя изба вдали от города". Однако, без контекста, это лишь предположение, и значение может быть разным в зависимости от контекста и языка.

OpenChat-3.5 + LEP-Extended

Фраза "моя хата с краю" является частью **русской народной мудрости** и имеет несколько значений. В целом, она означает что-то в духе "я живу на окраине, вдали от центра событий или общества", но может иметь и другие толкования в зависимости от контекста.

OpenChat-3.5 + LEP-Extended + Calibration (saiga d7 + copy task)

Фраза "моя хата с краю" означает, что **человек не хочет вмешиваться** в дела других людей или не хочет принимать участие в конфликте, предпочитая держаться подальше от него. Фраза происходит из **русской народной мудрости**, которая гласит: "Моя хата с краю, а я не влезу".

RuadaptQwen в лидербордах

Арена

Text-to-Image

Arena-Hard-Auto

SLAVA

PingPong

Quality vs Price

Simple-Evals

DeathMath Benchmark

POLLUX Бенчмарк

POLLUX Демо

Всего #моделей: 82. Всего #голосов: 88,864. Последнее обновление: 2025-08-10.

Ранг (UB) — это рейтинг модели по верхней границе. Он определяется как 1 плюс количество моделей, которые статистически превосходят данную модель. Модель А считается статистически лучше модели В, если нижняя граница её оценки превышает верхнюю границу оценки модели В (с доверительным интервалом 95%). См. Рисунок 1 ниже для наглядной визуализации доверительных интервалов.

Category

Запросы пользователей

Применить фильтр

☒ Style Control

☐ Показывать устаревшие

☐ Только 10b модели

☒ Только RU-модели

Запросы от пользователей сайта. Сортировка

Снижено влияние стилистики ответа на оценку

#модели: 82 (100%) #голоса: 88,864 (100%)

Rank* (UB)	Model	Arena Elo	95% CI	Votes	Organization
1	GigaChat.2.Max	1027	+18/-18	904	Sber
1	GigaChat-Max-preview.4.0.26.20	1019	+15/-14	1381	Sber
1	GigaChat.2.Pro	1012	+17/-17	876	Sber
1	RefalMachine/RuadaptQwen2.5-32B-Pro-Beta	1003	+21/-21	749	RefalMachine
1	YandexGPT.5.Pro	996	+17/-18	921	Yandex
1	t-tech/T-pro-it-1.0	993	+21/-23	547	t-bank-ai
3	saiga_llama3_70b	986	+19/-22	676	Ilya Gusev
3	Vikhrmodels/Vikhr-Nemo-12B-Instruct-R-21-09-24	975	+20/-19	859	Vikhrmodels
4	YandexGPT.4.Pro	971	+13/-13	2009	Yandex
4	GigaChat-Pro.4.0.26.20	967	+16/-17	1082	Sber
6	GigaChat.2.Lite	955	+18/-20	904	Sber
6	t-tech/T-lite-it-1.0	954	+23/-21	595	t-bank-ai
7	YandexGPT.3.Pro	952	+14/-13	1767	Yandex
9	GigaChat.4.0.26.20	942	+16/-15	1335	Sber

27

RuadaptQwen3: метрики



Table 6. Evaluation of the quality of trained Ruadapt models, original models and other existing adaptations

Model	Tokenizer	mean	ifeval	knowledge	long	math	down	sentiment	summary	translate
32B										
Qwen3-32B	original	53.6	79.3	68.0	58.0	63.5	50.0	24.3	23.1	62.5
RuadaptQwen3-32B-Hybrid	adapted	49.3	74.3	68.2	59.1	45.2	39.5	21.3	24.2	62.7
T-pro-it-2.0	adapted	49.0	66.8	69.3	56.3	61.3	43.0	10.5	21.9	62.8
8B										
Qwen3-8B	original	47.1	77.1	59.4	54.0	58.4	31.8	13.6	22.5	60.0
QVikhr-3-8B-Instruction	original	46.7	77.0	59.7	53.0	55.5	31.7	14.2	22.2	60.0
RuadaptQwen3-8B-Hybrid	adapted	44.4	73.8	59.6	55.0	40.9	30.7	13.0	22.1	60.3
4B										
Qwen3-4B	original	44.2	74.2	54.9	52.3	45.3	31.2	14.2	22.9	58.3
QVikhr-3-4B-Instruction	original	42.0	70.6	55.2	51.4	32.6	30.5	15.9	21.5	58.0
RuadaptQwen3-4B-Hybrid	adapted	40.5	68.3	54.8	50.5	29.9	28.5	11.5	22.3	58.4
Qwen3-4B-Instruct-2507	original	45.0	77.9	56.7	50.0	48.8	31.7	14.7	21.5	58.7
RuadaptQwen3-4B-Instruct	adapted	44.2	73.9	57.1	53.4	46.5	29.1	13.5	21.3	58.9

RuadaptQwen3: ускорение




Fig. 2. Comparison of generation speed of Qwen3 vs. RuadaptQwen3.

Оценка качества LLM

Обычная оценка качества в ML: 1) Есть четкая задача 2) Есть четкий вариант правильного и не правильного ответа 3) различные формулы оценки.

Как оценивать LLM, особенно инструктивные?


- zero-shot / few-shot при решении конкретных задач.
- Следование инструкциям.
- Полезность, вредность, токсичность.
- Сравнение side-by-side людьми
- Сравнение side-by-side намного более мощной LLM.

- Классический бенчмарк для оценки **знаний** модели.
- Вопросы с множественным выбором, 4 варианта ответа, оценка вероятности генерации A, B, C, D.
- Покрытие различных областей от физики до философии, разный уровень (колледж, старшая школа, профессиональный).
- Считают в zero-shot и few-shot с $k=5$.
 - Качество с few-shot у базовых и инстракт моделей обычно схожие.
- Для русского языка есть переводной вариант:
https://github.com/NLP-Core-Team/mmlu_ru

BigBench



- Оценка только на 1 MMLU или даже на паре задач недостаточно широко оценивает разные модели
- 200+ NLP задач
- Есть Lite и Hard версии



Проблемы современных бенчмарков



- Качество на конкретных задачах не отражает пользовательский опыт
- Сложно оценивать следование инструкциям
- Модели переобучают на то, чтобы иметь более высокие значения на бенчмарках

Вместо сравнения на бенчмарках: сравнение side-by-side.

- Сравнение за счет оценки людьми.
 - lmsys
- Сравнение за счет других больших моделей (llm as a judge)
 - MT-bench
 - alpaca-eval

[Arena \(battle\)](#)
[Arena \(side-by-side\)](#)
[Direct Chat](#)
[Vision Direct Chat](#)
[Leaderboard](#)
[About Us](#)

LMSYS Chatbot Arena: Benchmarking LLMs in the Wild

[Blog](#) | [GitHub](#) | [Paper](#) | [Dataset](#) | [Twitter](#) | [Discord](#)

Rules

- Ask any question to two anonymous models (e.g., ChatGPT, Claude, Llama) and vote for the better one!
- You can continue chatting until you identify a winner.
- Vote won't be counted if model identity is revealed during conversation.

Arena Elo [Leaderboard](#)

We collect 500K+ human votes to compute an Elo-based LLM leaderboard. Find out who is the 🏆 LLM Champion!

[Chat now!](#)

Expand to see the descriptions of 36 models

Model A

Что такое глазунья?

Глазунья — это блюдо из яиц, приготовленное путём жарки на сковороде без помешивания. В иных странах это блюдо известно как яичница-глазунья или просто жареные яйца. Яйца аккуратно разбивают так, чтобы желток остался целым, и жарят на небольшом количестве масла или сливочного масла. Жарить их можно до разной степени готовности желтка — от слегка текучего до полностью застывшего.

Глазунью часто подают на завтрак, дополняя тостами, овощами или мясными изделиями, такими как бекон или колбасы. Это очень популярное и простое в приготовлении блюдо, которое можно встретить почти в каждой кухне мира.

Model B

Что такое глазунья?

Глазунья — это блюдо, представляющее собой яйца, жаренные на сковороде без перемешивания, таким образом, чтобы желток остался целым и мягким. В некоторых странах и регионах глазунью также называют яичницей-глазуньей. При приготовлении глазуньи обычно стараются не повредить желток, чтобы он остался жидким или полужидким, а белок полностью застыл. Блюдо может подаваться с различными добавками, такими как свежие травы, сыр, овощи или колбасные изделия, в зависимости от предпочтений.

A is better

B is better

Tie

Both are bad

Enter your prompt and press ENTER

Send

New Round

Regenerate

Share

🏆 LMSYS Chatbot Arena Leaderboard

[Vote](#) | [Blog](#) | [GitHub](#) | [Paper](#) | [Dataset](#) | [Twitter](#) | [Discord](#)

LMSYS [Chatbot Arena](#) is a crowdsourced open platform for LLM evals. We've collected over 500,000 human preference votes to rank LLMs with the Elo ranking system.

Arena Elo

Full Leaderboard

Total #models: 81. Total #votes: 634676. Last updated: April 9, 2024.

Contribute your vote 🗳️ at [chat.lmsys.org](#)! Find more analysis in the [notebook](#).

Rank	Model	Arena Elo	95% CI	Votes	Organization	License	Knowledge Cutoff
1	Claude-3-Opus	1256	+3/-4	47589	Anthropic	Proprietary	2023/8
1	GPT-4-1106-Preview	1254	+3/-4	62657	OpenAI	Proprietary	2023/4
1	GPT-4-0125-Preview	1250	+3/-3	47631	OpenAI	Proprietary	2023/12
4	Bard (Gemini-Pro)	1208	+5/-5	12468	Google	Proprietary	Online
4	Claude-3-Sonnet	1204	+3/-3	57740	Anthropic	Proprietary	2023/8
6	Command-R+	1194	+5/-5	17404	Cohere	CC-BY-NC-4.0	2024/3
6	GPT-4-0314	1189	+4/-3	41292	OpenAI	Proprietary	2021/9
8	Claude-3-Haiku	1182	+3/-4	50689	Anthropic	Proprietary	2023/8
9	GPT-4-0613	1164	+3/-3	60213	OpenAI	Proprietary	2021/9
9	Mistral-Large-2402	1158	+3/-4	35075	Mistral	Proprietary	Unknown
10	Qwen1.5-72B-Chat	1153	+4/-5	27050	Alibaba	Qianwen LICENSE	2024/2
10	Claude-1	1150	+5/-5	21868	Anthropic	Proprietary	Unknown
11	Command-R	1149	+3/-3	31871	Cohere	CC-BY-NC-4.0	2024/3
11	Mistral-Medium	1148	+4/-5	29807	Mistral	Proprietary	Unknown
15	Qwen1.5-32B-Chat	1138	+4/-6	12130	Alibaba	Qianwen LICENSE	2024/2

Note: we take the 95% confidence interval into account when determining a model's ranking. A model is ranked higher only if its lower bound of model score is higher than the upper bound of the other model's score. See Figure 3 below for visualization of the confidence intervals.

- Тест сетки утекают в модели
- Выход - “живой” бенчмарк
- Новые задачи каждые X времени
- Сложно поддерживать, но полезно для сравнения фронтиров

LiveBench A Challenging, Contamination-Free LLM Benchmark


LiveBench appeared as a [Spotlight Paper](#) in ICLR 2025.
This work is sponsored by [Abacus.AI](#)

[Leaderboard](#) [Details](#) [Code](#) [Data](#) [Paper](#)

Model	Organization	Global Average	Reasoning Average	Coding Average	Agentic Coding Average	Mathematics Average	Data Analysis Average	Language Average	IF Average
Gemini 3.1 Pro Preview High* *5th rank in unseen questions across all categories	Google	79.93	84.00	76.45	65.00	91.04	78.54	85.38	79.10
Claude 4.6 Opus Thinking High Effort	Anthropic	76.33	88.67	78.18	61.67	89.32	69.89	83.27	63.31
Claude 4.5 Opus Thinking High Effort	Anthropic	75.96	80.09	79.65	63.33	90.39	74.44	81.26	62.55
Claude 4.6 Sonnet Thinking Medium Effort	Anthropic	75.47	84.77	79.27	60.00	86.99	77.95	76.10	63.22
GPT-5.2 High	OpenAI	74.84	83.21	76.07	51.67	93.17	78.16	79.81	61.77
GPT-5.2 Codex	OpenAI	74.30	77.71	83.62	51.67	88.77	78.20	73.68	66.45
GPT-5.1 Codex Max High	OpenAI	73.98	83.65	80.68	53.33	83.22	70.12	76.48	70.38
Gemini 3 Pro Preview High	Google	73.39	77.42	74.60	55.00	81.84	74.39	84.62	65.85
GPT-5.3 Codex High	OpenAI	72.76	80.15	78.18	55.00	87.84	62.69	80.09	65.38
Gemini 3 Flash Preview High	Google	72.40	74.55	73.90	40.00	84.17	74.77	84.56	74.86
GPT-5.1 High	OpenAI	72.04	78.79	72.49	53.33	86.90	69.61	79.26	63.90
GPT-5 Pro	OpenAI	70.48	81.69	72.11	51.67	86.17	57.04	80.69	63.96
Kimi K2.5 Thinking	Moonshot AI	69.07	75.96	77.86	48.33	84.87	61.36	77.67	57.41
GLM 5	Z.AI	68.85	69.11	73.64	55.00	83.46	67.90	77.53	55.33

- В последнее время один из важнейших навыков LLM не просто генерация кода, а полноценная разработка

SWE-rebench: A Continuously Evolving and Decontaminated Benchmark for Software Engineering LLMs



Russian Super Glue



Московский
государственный
университет
имени М.В. Ломоносова

- Относительно старый бенчмарк на данный момент.
- Содержит 9 различных датасетов.
- Имеет тренировочные данные для каждого из них.
- Уровень “человека” с учетом обучения по сути уже давно превзойден.

Russian Super Glue



Московский
государственный
университет
имени М.В. Ломоносова

Leaderboard

We have improved the datasets. Please, change the leaderboard for the version (1.0/1.1) you are looking for, clicked on the button below.
You can switch between the scores and inference speed leaderboard as well. Click on the button Performance.

Version 1.0

Performance*

* More information about speed scores and RAM are available [here](#).

Rank	Name	Team	Link	Score	LiDiRus	RCB	PARus	MuSeRC	TERRa	RUSSE	RWSD	DaNetQA	RuCoS
1	HUMAN BENCHMARK	AGI NLP	i	0.811	0.626	0.68 / 0.702	0.962	0.806 / 0.42	0.92	0.805	0.84	0.915	0.93 / 0.89
2	ruadapt Solar 10.7 twostage	RCC MSU	i	0.805	0.591	0.597 / 0.594	0.916	0.946 / 0.837	0.927	0.739	0.844	0.933	0.82 / 0.797
3	Mistral 7B LoRA	Saiga team	i	0.763	0.46	0.529 / 0.573	0.824	0.927 / 0.787	0.888	0.758	0.786	0.919	0.83 / 0.816
4	FRED-TS 1.7B finetune	SberDevices	i	0.762	0.497	0.497 / 0.541	0.842	0.916 / 0.773	0.871	0.823	0.669	0.889	0.9 / 0.902
5	Golden Transformer v2.0	Avengers Ensemble	i	0.755	0.515	0.384 / 0.534	0.906	0.936 / 0.804	0.877	0.687	0.643	0.911	0.92 / 0.924
6	LLaMA-2 13B LoRA	Saiga team	i	0.718	0.398	0.489 / 0.543	0.784	0.919 / 0.761	0.793	0.74	0.714	0.907	0.78 / 0.76
7	Saiga 13B LoRA	Saiga team	i	0.712	0.436	0.439 / 0.5	0.694	0.898 / 0.704	0.865	0.728	0.714	0.862	0.85 / 0.83
8	YaLM p-tune (3.3B frozen + 40k trainable params)	Yandex	i	0.711	0.364	0.357 / 0.479	0.834	0.892 / 0.707	0.841	0.71	0.669	0.85	0.92 / 0.916
9	ruadapt LLaMA-2 7B LoRA	RCC MSU	i	0.71	0.417	0.545 / 0.555	0.756	0.894 / 0.695	0.876	0.668	0.708	0.878	0.76 / 0.733
10	FRED-TS large finetune	SberDevices	i	0.706	0.389	0.456 / 0.546	0.776	0.887 / 0.678	0.801	0.775	0.669	0.799	0.87 / 0.863
11	RuLeanALBERT	Yandex Research	i	0.698	0.403	0.361 / 0.413	0.796	0.874 / 0.654	0.812	0.789	0.669	0.76	0.9 / 0.902
12	FRED-TS 1.7B (only encoder 760M) finetune	SberDevices	i	0.694	0.421	0.311 / 0.441	0.806	0.882 / 0.666	0.831	0.723	0.669	0.735	0.91 / 0.911
13	ruTS-large finetune	SberDevices	i	0.686	0.32	0.45 / 0.532	0.764	0.855 / 0.608	0.775	0.773	0.669	0.79	0.86 / 0.859
14	ruRoberta-large finetune	SberDevices	i	0.684	0.343	0.357 / 0.518	0.722	0.861 / 0.63	0.801	0.748	0.669	0.82	0.87 / 0.867
15	gst-3.5-turbo zero-shot	Saiga team	i	0.682	0.422	0.484 / 0.505	0.888	0.817 / 0.532	0.795	0.596	0.714	0.878	0.68 / 0.667
16	Golden Transformer v1.0	Avengers Ensemble	i	0.679	0.0	0.406 / 0.546	0.908	0.941 / 0.819	0.871	0.587	0.545	0.917	0.92 / 0.924
17	xlm-roberta-large (Facebook) finetune	SberDevices	i	0.654	0.369	0.328 / 0.457	0.59	0.809 / 0.501	0.798	0.765	0.669	0.757	0.89 / 0.886
18	mdeberta-v3-base (Microsoft) finetune	SberDevices	i	0.651	0.332	0.27 / 0.489	0.716	0.825 / 0.531	0.783	0.727	0.669	0.708	0.87 / 0.868
19	Saiga2 70B zero-shot	Saiga team	i	0.643	0.365	0.385 / 0.461	0.82	0.669 / 0.098	0.811	0.59	0.831	0.878	0.69 / 0.678
20	Saiga Mistral 7B zero-shot	Saiga team	i	0.635	0.322	0.436 / 0.5	0.698	0.84 / 0.553	0.807	0.587	0.727	0.839	0.58 / 0.571
21	ruTS-base finetune	SberDevices	i	0.635	0.267	0.423 / 0.461	0.636	0.808 / 0.475	0.736	0.707	0.669	0.769	0.85 / 0.847
22	ruBert-large finetune	SberDevices	i	0.62	0.235	0.356 / 0.5	0.656	0.778 / 0.436	0.704	0.707	0.669	0.773	0.81 / 0.805

МЕРА: текст



- Основной разработчик бенча: Альянс ИИ (по сути основные усилия от Сбер)
- Содержит 21 задачу
- Оценка на тест сетах на стороне бенчмарка
 - Но генерация ответов на пользователя

Модель, команда	Результат	RWSD	PARus	RCB	MultiQ	ruWorldTree	ruOpenBookQA	CheGeKa
1 GPT4o MERA	0.642	0.496	0.944	0.557 / 0.521	0.572 / 0.431	0.985 / 0.985	0.935 / 0.935	0.553 / 0.464
2 Meta-Llama-3.1-405B-Instr... MERA	0.59	0.677	0.902	0.598 / 0.548	0.623 / 0.453	0.981 / 0.981	0.955 / 0.765	0.506 / 0.413
3 GigaChat Max GIGACHAT	0.588	0.665	0.928	0.58 / 0.423	0.486 / 0.322	0.975 / 0.975	0.918 / 0.737	0.469 / 0.397
4 Mistral-Large-Instruct-2... MERA	0.574	0.635	0.932	0.55 / 0.531	0.63 / 0.471	0.975 / 0.975	0.915 / 0.915	0.458 / 0.356
5 GPT4o-mini MERA	0.57	0.577	0.918	0.571 / 0.507	0.509 / 0.379	0.956 / 0.956	0.875 / 0.874	0.293 / 0.233
6 Qwen2-72B-Instruct MERA	0.57	0.658	0.944	0.511 / 0.484	0.58 / 0.447	0.985 / 0.789	0.945 / 0.945	0.324 / 0.267
7 Qwen2.5-72B-Instruct-A... mizirovity	0.567	0.619	0.93	0.573 / 0.539	0.564 / 0.426	0.987 / 0.987	0.935 / 0.935	0.172 / 0.12
8 Meta-Llama-3.1-70B-Instr... MERA	0.554	0.554	0.932	0.596 / 0.526	0.607 / 0.443	0.977 / 0.977	0.913 / 0.731	0.353 / 0.291
9 Meta-Llama-3-70B-Instr... MERA	0.528	0.519	0.892	0.587 / 0.493	0.595 / 0.421	0.958 / 0.958	0.905 / 0.727	0.327 / 0.269
10 GigaChat Pro GIGACHAT	0.516	0.362	0.884	0.575 / 0.258	0.302 / 0.212	0.931 / 0.931	0.873 / 0.7	0.397 / 0.329
11 Phi-3.5-MoE-Instruct MERA	0.487	0.465	0.864	0.546 / 0.486	0.446 / 0.349	0.971 / 0.971	0.88 / 0.88	0.178 / 0.139
12 Mixtral-8x22B-Instruct-... MERA	0.486	0.473	0.87	0.578 / 0.372	0.521 / 0.366	0.916 / 0.733	0.835 / 0.669	0.338 / 0.267
13 Qwen1.5-72B-Chat MERA	0.482	0.377	0.904	0.521 / 0.456	0.452 / 0.318	0.931 / 0.932	0.86 / 0.86	0.119 / 0.082
14 GigaChat Lite+ GIGACHAT	0.477	0.435	0.85	0.53 / 0.278	0.287 / 0.208	0.886 / 0.886	0.785 / 0.63	0.268 / 0.214
15 GigaChat Lite GIGACHAT	0.477	0.427	0.842	0.523 / 0.275	0.285 / 0.207	0.89 / 0.89	0.78 / 0.626	0.274 / 0.219
16 Qwen2-72B-Instruct MERA	0.471	0.342	0.894	0.541 / 0.449	0.48 / 0.348	0.941 / 0.941	0.888 / 0.888	0.19 / 0.144
17 Phi-3-medium-4k-instruct MERA	0.465	0.488	0.896	0.495 / 0.435	0.361 / 0.174	0.962 / 0.962	0.873 / 0.873	0.135 / 0.091
18 ruadapt-llama3-8B-instr... RCC MSU	0.447	0.542	0.828	0.534 / 0.446	0.483 / 0.334	0.838 / 0.837	0.773 / 0.772	0.146 / 0.101
19 Qwen2-7B-Instruct MERA	0.445	0.462	0.82	0.541 / 0.353	0.442 / 0.333	0.926 / 0.742	0.783 / 0.782	0.069 / 0.043
20 Phi-3-medium-128k-inst... MERA	0.441	0.485	0.9	0.546 / 0.459	0.361 / 0.162	0.954 / 0.764	0.863 / 0.691	0.134 / 0.087
21 Phi-3-small-8k-instruct MERA	0.438	0.523	0.836	0.55 / 0.398	0.361 / 0.231	0.935 / 0.749	0.825 / 0.661	0.08 / 0.053

AMERA: code и multi



Московский
государственный
университет
имени М.В. Ломоносова

AMERA Code

Text Industrial **Code** Multi

Лидерборд Задачи Как работает AMERA

<Бенчмарк для современных кодовых LLM>

	Модель, команда	Общий total	Приватный total	YABLoCo	stRuCom	RealCode	UnitTests	ruCodeEval
1	GPT-5.1-Codex-Max MERA	0.54	0.656	0.077 / 0.034	0.383	0.485 / 0.929	0.323	0.632 / 0.845 / 0.89
2	Claude Opus 4.6 MERA	0.472	0.5	0.13 / 0.149	0.318	0.501 / 0.943	0.367	0.245 / 0.29 / 0.299
3	GigaChat3-Ultra-702B-... GigaChat	0.388	0.431	0.082 / 0.043	0.275	0.332 / 0.988	0.204	0.474 / 0.566 / 0.585
4	GPT-4.1 MERA	0.381	0.382	0.144 / 0.034	0.297	0.418 / 0.988	0.201	0.443 / 0.484 / 0.494
5	Gemini 2.5 flash MERA	0.36	0.427	0.12 / 0.029	0.217	0.388 / 0.988	0.212	0.61 / 0.645 / 0.652
6	DeepSeek-Coder-V2-Ins... MERA	0.35	0.36	0.149 / 0.034	0.2	0.364 / 0.988	0.188	0.433 / 0.45 / 0.457
7	GigaChat-2-Max MERA	0.338	0.361	0.091 / 0.014	0.291	0.318 / 0.986	0.223	0.534 / 0.581 / 0.591
8	MiniMax-M2.5 MERA	0.332	0.566	0.053 / 0.014	0.097	0.365 / 0.96	0.118	0.304 / 0.737 / 0.841
9	RuadapTQwen3-8B-Hybr... RDC MSU	0.326	0.38	0.115 / 0.014	0.244	0.191 / 0.986	0.218	0.419 / 0.548 / 0.598
10	Qwen3-Coder-480B-A3... MERA	0.326	0.329	0.082 / 0.019	0.202	0.411 / 0.986	0.231	0.463 / 0.466 / 0.47

AMERA Multi

Text Industrial Code **Multi**

Лидерборд Задачи Как работает AMERA

Бенчмарк для современных мультимодальных LLM

Общий рейтинг по всем модальностям	Лучшие LLMs в изображениях
Human 0.871	Human 0.8
Qwen3-Omni-30B-A3B-Instruct 0.5	Qwen3-Omni-30B-A3B-Instruct 0.554
Qwen2.5-Omni-7B 0.317	GPT 4.1 0.478
Лучшие LLMs в аудио	Лучшие LLMs в видео
Human 0.894	Human 0.92
Qwen3-Omni-30B-A3B-Instruct 0.561	Qwen3-VL-32B-Instruct 0.664
Qwen2.5-Omni-7B 0.474	Qwen2.5-VL-72B-Instruct 0.625



SWE-MERA – a dynamic alternative to SWE-bench

[Code](#) [Dataset](#) [Submit](#)

01/09/2024						
01/06/2025						
Position	Model	pass@1 ↑	pass1_std ↓	pass@6 ↓	Tasks ↓	Trajectory
1	aider-deepseek-r1	29.67%	1.69	42.86%	728	link
2	aider-Devstral-24B	17.31%	1.40	29.81%	728	link
3	aider-DeepSeek-R1-DQ32B	14.56%	1.31	25.96%	728	link
4	aider-Qwen2.5-Coder-32B	13.19%	1.25	22.66%	728	link
5	aider-Qwen3-32B	12.91%	1.24	25.41%	728	link
6	aider-QwQ-32B	12.23%	1.21	24.45%	728	link
7	aider-Llama-3.3-70B	9.48%	1.09	16.21%	728	link
8	aider-Qwen2.5-Coder-14B	8.79%	1.05	19.37%	728	link
9	aider-Codestral-v0.1	3.98%	0.72	9.20%	728	link

Spaces Vikhrmodels small-shlepa-lb Like 9 Running

App Files Community

Small Shlepa LLM Leaderboard

LLM Benchmark Submit Analytics

Search

Separate multiple queries with ` `

Show Rows with the Following Values

Select Columns to Display:

☒ mmluprora ☒ moviesmc ☒ musicmc ☒ lawmc ☒ booksmc ☐ model_dtye ☐ ppl

model	mmluprora	moviesmc	musicmc	lawmc	booksmc	avg
BlackSamorez/TechGenus/Mistral-large-Instruct-2407-AWQ	0.276	0.715	0.306	0.623	0.446	0.473
RefalMachine/zvadpt_llama3_8b_instruct_extended_led_ft	0.225	0.475	0.311	0.617	0.392	0.404
RefalMachine/openchat-3.5-0106	0.223	0.454	0.291	0.624	0.39	0.396
RefalMachine/IlyaGusev_saiga_llama3_8b	0.219	0.475	0.319	0.608	0.361	0.396
google/gemma-2-9b	0.262	0.595	0.255	0.582	0.336	0.388
apsys/vikhr-it-5.4-fp16-orpo-v2	0.188	0.47	0.281	0.643	0.334	0.383
apsys/T-lite-instruct-0.1	0.18	0.47	0.281	0.532	0.336	0.36
Vikhrmodels/it-5.2-fp16-cp	0.201	0.454	0.268	0.539	0.307	0.354
lightblue/suzume-llama-3-8b-multilingual	0.194	0.329	0.26	0.518	0.297	0.319
LakoMoor/Vikhr-2.5-7b-it	0.169	0.329	0.166	0.319	0.21	0.238
apsys/llama3_overfitted	0.124	0.1	0.077	0.232	0.087	0.124

Бенчмарк от Vikhr: “mmlu” с выбором из 12 вариантов

LLMTF-Benchmark (in progress)



Московский
государственный
университет
имени М.В. Ломоносова

Оценка на 55 задачах

+

llm as a judge arena

Model	Mean	Total Time (s)	IFEval	Knowledge	Long	RAG	Skills
Qwen3.5-27B (2xGPU)	0.718 ± 0.004	30181	0.815 ± 0.017	0.733 ± 0.006	0.631 ± 0.010	0.866	0.503 ± 0.004
Qwen3.5-35B-A3B (2xGPU)	0.701 ± 0.003	12519	0.823 ± 0.011	0.742 ± 0.005	0.599 ± 0.006	0.868	0.470 ± 0.004
T-pro-it-2.1	0.691 ± 0.003	66586	0.805 ± 0.013	0.708 ± 0.005	0.620 ± 0.006	0.870	0.454 ± 0.004
Qwen3-32B	0.682 ± 0.003	74544	0.797 ± 0.012	0.682 ± 0.005	0.611 ± 0.005	0.875	0.446 ± 0.004
RuadaptQwen3-32B-Instruct	0.671 ± 0.003	53852	0.751 ± 0.013	0.676 ± 0.005	0.629 ± 0.006	0.872	0.428 ± 0.004
Qwen3-14B	0.670 ± 0.003	32618	0.815 ± 0.011	0.641 ± 0.006	0.603 ± 0.006	0.868	0.422 ± 0.004
Qwen3-30B-A3B-Instruct-2507	0.669 ± 0.003	21103	0.786 ± 0.013	0.676 ± 0.006	0.591 ± 0.005	0.860	0.433 ± 0.004
T-lite-it-2.1	0.657 ± 0.003	15364	0.795 ± 0.013	0.631 ± 0.005	0.607 ± 0.005	0.843	0.410 ± 0.004
T-pro-it-2.0	0.650 ± 0.003	59405	0.672 ± 0.012	0.697 ± 0.005	0.618 ± 0.005	0.878	0.386 ± 0.004
Qwen3-8B	0.642 ± 0.003	20459	0.783 ± 0.011	0.596 ± 0.005	0.572 ± 0.005	0.843	0.413 ± 0.004
YandexGPT-5-Lite-8B-instruct	0.633 ± 0.003	23602	0.714 ± 0.013	0.655 ± 0.005	0.540 ± 0.006	0.858	0.396 ± 0.004
Qwen3-4B-Instruct	0.622 ± 0.003	14998	0.783 ± 0.014	0.567 ± 0.005	0.541 ± 0.005	0.828	0.392 ± 0.004
RuadaptQwen3-8B-Hybrid	0.622 ± 0.003	15171	0.746 ± 0.012	0.595 ± 0.005	0.563 ± 0.005	0.834	0.369 ± 0.004
RuadaptQwen3-4B-Instruct	0.613 ± 0.003	11270	0.751 ± 0.013	0.574 ± 0.005	0.565 ± 0.005	0.827	0.347 ± 0.004
Qwen3-4B	0.604 ± 0.003	15003	0.744 ± 0.013	0.551 ± 0.005	0.526 ± 0.006	0.826	0.375 ± 0.004
avibe	0.603 ± 0.004	15251	0.604 ± 0.016	0.632 ± 0.005	0.547 ± 0.005	0.847	0.387 ± 0.004
GigaChat3-10B-A1.8B-bf16	0.595 ± 0.004	12987	0.554 ± 0.018	0.645 ± 0.005	0.567 ± 0.005	0.857	0.353 ± 0.004
T-lite-it-1.0	0.581 ± 0.004	18474	0.579 ± 0.016	0.621 ± 0.005	0.533 ± 0.006	0.844	0.328 ± 0.003
Vikhr-Nemo-12B-Instruct-R-21-09-24	0.569 ± 0.004	25495	0.544 ± 0.016	0.558 ± 0.005	0.535 ± 0.005	0.862	0.344 ± 0.004
RuadaptQwen2.5-7B-Lite-Beta	0.557 ± 0.003	13696	0.514 ± 0.015	0.605 ± 0.005	0.528 ± 0.006	0.841	0.297 ± 0.004

Model	Elo Rating	STD	95% CI	Median Length (chars)
T-pro-it-2.0	1588	22	[1552, 1635]	2256
Qwen3-235B-A22B-Instruct-2507	1519	9	[1500, 1537]	1858
T-pro-it-2.1	1486	20	[1450, 1531]	1811
Qwen3.5-27B	1474	20	[1438, 1512]	2134
Qwen3.5-35B-A3B	1442	18	[1412, 1479]	2149
Qwen3-30B-A3B-Instruct-2507	1429	19	[1391, 1465]	2152
T-lite-it-2.1	1396	18	[1362, 1429]	1978
Qwen3-32B	1261	14	[1236, 1288]	1551
RuadaptQwen3-32B-Instruct	1235	15	[1209, 1271]	1646
Qwen3-4B-Instruct-2507	1228	15	[1200, 1258]	2267
Qwen3-14B	1201	16	[1168, 1232]	1624
RuadaptQwen3-4B-Instruct	1176	15	[1153, 1207]	1979
avibe	1175	13	[1149, 1198]	1728
RuadaptQwen3-8B-Hybrid	1173	13	[1148, 1200]	1492
Qwen3-8B	1147	16	[1115, 1171]	1729
RuadaptQwen2.5-7B-Lite-Beta	1083	14	[1062, 1113]	1252
gpt-4-1106-preview	1030	9	[1013, 1046]	1261
Qwen3-4B	1001	15	[972, 1028]	1636
T-lite-it-1.0	1000	16	[980, 1038]	1407
gpt-4o-mini	1000	0	[1000, 1000]	876
GigaChat3-10B-A1.8B-bf16	961	15	[931, 987]	959
Vikhr-Nemo-12B-Instruct-R-21-09-24	932	14	[909, 962]	1540
YandexGPT-5-Lite-8B-instruct	794	21	[752, 835]	636

Арена (анонимно) Арена (сравнение) Таблица лидеров О нас

LLM Arena: Бенчмарк LLM моделей на русском языке

llmarena.ru - ИСПОЛЬЗУЙТЕ БЕСПЛАТНО ПОСЛЕДНИЕ ВЕРСИИ ЛУЧШИХ ЧАТ-БОТОВ НА РУССКОМ

Правила

- Задайте любой вопрос двум моделям (например, ChatGPT, T-lite, Saiga) и выберите лучший ответ!
- Продолжайте общение до тех пор, пока не выберете победителя.
- Нажмите "Очистить историю", чтобы начать новый диалог.

Выберите две модели для общения и сравнения

YandexGPT 4 Pro

RefalMachine/roadapt_llama3_instruct_lep_saiga_kto_abliterated

Разверните, чтобы увидеть описание групп моделей (всего: 31)

Модель A

Напиши функцию на языке Python, которая обрабатывает текст на русском и английском языках и удаляет из него все html теги и пунктуацию.

Вот пример функции на Python, которая удаляет HTML-теги и пунктуацию из текста на русском и английском языках:

```
import re

def clean_text(text):
    # Удаление HTML-тегов
    text = re.sub('<.*>', '', text)

    # Замена всех знаков пунктуации на пробелы
    punctuation = '.,:;!()-[]{}:'''',<.>/?@#%$&*~_'"
    for char in punctuation:
        text = text.replace(char, ' ')

    return text

# Пример использования функции
text = "hello, world! <b>This is a test</b>"
clean_text_result = clean_text(text)
print("Исходный текст:", text)
print("Очищенный текст:", clean_text_result)
```

Эта функция сначала удаляет все HTML-теги с помощью регулярного выражения, а затем заменяет все знаки пунктуации на пробелы. Вы можете использовать эту функцию для обработки текстов на русском и английском языках.

Модель B

Напиши функцию на языке Python, которая обрабатывает текст на русском и английском языках и удаляет из него все html теги и пунктуацию.

Вот функция на языке Python, которая удаляет HTML теги и пунктуацию из текста на русском и английском языках:

```
import re
from bs4 import BeautifulSoup

def remove_tags_and_punctuation(text):
    # Использовать BeautifulSoup для удаления HTML тегов
    soup = BeautifulSoup(text, 'html.parser')
    text = soup.get_text()

    # Использовать регулярные выражения для удаления пунктуации
    text = re.sub(r'[^\w\s-]', '', text)

    return text

# Пример использования
text = '<html><body><p>Это тестовый текст на русском и английском языках.</p></body></html>'
print(remove_tags_and_punctuation(text))
```

Эта функция использует модуль BeautifulSoup для удаления HTML тегов и регулярные выражения для удаления пунктуации. В примере, текст сначала преобразуется в Unicode для корректного использования символов всех языков.

А лучше

В лучше

Ничья

Обе плохо

Ru Arena General



Московский
государственный
университет
имени М.В. Ломоносова

- Тоже от Vikhr
- llm-as-judge
 - gpt4o
- Сравнивается против gpt-3.5

LLM Benchmark About Submit here!

Search

Separate multiple queries with ";"

Select Columns to Display:

☒ score ☒ 95% CI ☐ lower ☐ upper ☒ avg_tokens ☒ std_tokens
☒ lc_score

model	score	95% CI	avg_tokens	std_tokens	lc_score
DeepSeek - DeepSeek-V3-Chat	96.3	+0.7 / -0.8	665.97	504.83	56.62
-chatgpt-4o-latest	94.75	+0.8 / -0.7	693.15	634.2	56.4
yi-lightning	93.46	+0.9 / -0.9	636.68	469.74	56.22
o1-mini	93.45	+0.7 / -0.8	791.18	647.74	56.22
RefalMachine-RuadaptQwen-32B-Pro_v1	92.18	+1.2 / -1.2	563.43	387.83	56.04
claude-3-opus-20240229	91.3	+1.0 / -1.1	468.69	254.1	55.92
gpt-4-1106-preview	90.89	+1.1 / -1.1	541.66	346.59	55.86
T-Tech-T-pro-it-1.0	90.87	+1.1 / -1.2	502	380.68	55.85
o1-preview	90.8	+0.9 / -1.0	664.89	601.34	55.84
RefalMachine-RuadaptQwen2.5-32B-instruct-v1	90.47	+1.1 / -1.0	527.86	366.54	55.8
SberDevices-GigaChatMaxWithoutFilter	89.96	+1.2 / -1.4	523.95	421.87	55.73
DeepSeek, Inc. -DeepSeek-V2-Chat-0628	89.67	+1.3 / -1.1	514.79	340.79	55.68



- Известный фреймворк для оценки LLM
- На нем основаны
 - MERA
 - shlepa
 - и др. англ. бенчмарки
- Имеет ряд достоинств и некоторые недостатки (которые со временем исправляют)
 - Нельзя нормально тестировать вариант, когда часть ответа модели уже дана
 - Сложный код с большим количеством legacy



- Разрабатываемый нами фреймворк для оценки LLM
- Можно оценивать генерации, вероятность токена, вероятность последовательности
- Поддержка рассуждающих моделей
- В основе messages формат работы с моделями.
- Относительно простой способ добавления своих task
- Информативные log файлы (но много весят)
- Статья в процессе рецензирования

- Задача сравнения больших языковых моделей до сих пор большая проблема.
- Количество различных англоязычных бенчмарков велико (а какой лучший?), но русскоязычных достаточно мало.
- А что делать с конкретными предметными областями и задачами?

- Арены позволяют сравнивать модели максимально приближенно к усредненному качеству для задач среднего пользователя, но поддерживать их дорого и свои модели на них не протестировать.
- Обычных же бенчмарков в общем случае недостаточно, так как происходит переобучение на их задачи (иногда намеренное).

Домашнее задание 2



Цель задания:

Найти и выбрать какую-либо задачу (поискать на huggingface с тегом Russian или любым другим образом) и оценить с помощью нее 2 модели на выбор.

- Важно выбрать ту задачу, которую можно оценить на основе генерации LLM
- Например, NER, где модель обязана генерировать ответ в структурированном виде, который легко парсить

Домашнее задание 2



Важно:

- Нужно выбрать генеративную задачу! Однако, любую не генеративную задачу можно переформулировать в генеративную
 - Было предсказание A / B / C / D и оценка вероятности -> стало предсказание, например, {"answer": "A"}
- Текущее ДЗ часто не делается быстро и просто
- Если в датасете много сэмплов - возьмите только 20-100 и оценивайте на них
- Функция оценки качества должна быть явно выделена!

Задание: оценивание и сроки



- Срок 1 неделя: до 15 марта 23:59.
- Присылать на tikhomirov.mm@gmail.com
 - Название письма: Основы LLM 2026: Задание 2, evaluation.
 - В письме Ваше полное ФИО, группа, решение и краткий отчет по нему в PDF.
- Оценка по шкале “-/-+/-+/-++”.
 - ++ за те решения, которые особо мне понравятся чем-либо.