

Для тестирования я выбрал 2 датасета: RussianNLP/coat и RussianNLP/russian_super_glue.

Из 1 датасета я взял задачу классификации текстов на 2 класса - на человеческий и ИИ. Чтобы преобразовать задачу в генеративную, указал в промте, чтобы модель написала класс.

Из 2 датасета взял задачу "Выбор правдоподобных альтернатив для русского языка" (Choice of Plausible Alternatives for Russian language (PARus)), написал промт, чтобы задача была генеративной.

Сравнивал модели RefalMachine/RuadaptQwen3-4B-Instruct и LiquidAI/LFM2.5-1.2B-Instruct.

Использовал метрики acc и f1.

Результаты Qwen:

Coat

Результаты zero-shot оценки на 100 примерах:

Accuracy: 0.7300

Precision: 0.7879

Recall: 0.5652

F1-score: 0.6582

PARus

Accuracy на 100 примерах: 0.9100

Precision: 0.9038

Recall: 0.9216

F1-score: 0.9126

Результаты Liquid:

Coat

Результаты zero-shot оценки на 100 примерах:

Accuracy: 0.5400

Precision: 0.0000

Recall: 0.0000

F1-score: 0.0000

PARus

Accuracy на 100 примерах: 0.5200

Precision: 0.5155

Recall: 0.9804

F1-score: 0.6757

Выводы:

Между результатами огромная пропасть. У Qwen есть преимущества в виде Ruadapt и размера, но Liquid совсем не справляется. На первом датасете она всегда выдает 0.

Распределение истинных меток: Counter({0: 54, 1: 46})

Распределение предсказанных меток: Counter({0: 100})

Это означает, что она не нашла никаких зависимостей. На мой взгляд этот датасет был трудным, так как текст был коротким, однако Qwen смог показать неплохую acc и f1.

Второй датасет был попроще, чем первый, и здесь у Liquid хотя бы f1 не равняется нулю, но точность очень слабая. Qwen показывает идеальный результат, acc и f1 больше 0.9

По результатам первого задания, можно было предположить уверенную победу Qwen, но никак не отсутствие сопротивления Liquid.