

Задание

Взять датасет

https://huggingface.co/datasets/bearberry/rus_xquadqa

- Все сегменты объединить в один корпус
 - Внимание на повторы!
- Поднять векторную БД Qdrant (:memory:) и проиндексировать корпус.
- Завернуть все в langchain, реализовав функцию поиска по БД.
- На основе функции поиска и LLM реализовать RAG систему.
- Вывести ответы на топ 10 запросов из датасета 2 разными моделями, сравнить их по отношению к эталону

Был загружен датасет и переведен в DF. После создания корпуса были убраны дубликаты.

Поднял Qdrant и модель E5 для эмбедингов.

Обернул в langchain. (Возможно можно было объединить 2 пункта в один, ведь для langchain я снова подгружал E5.

Но я столкнулся с странными ошибками, из-за которых я не мог использовать методы `get_relevant_documents`, `search`.

В ошибке было указано, что таких методов нет. Deepseek сказал, что проблема в версиях qdrant и langchain.

Deepseek мне предлагал свежие методы `invoke`, `query_points`, но с ними не получалось работать с `retriever`.

Я загрузил qdrant 1.7.3 и просто добился, чтобы код работал.)

На основе вопроса подбирал документы через ретривер и вставлял их в промт модели.

Для сравнения я взял LiquidAI/LFM2.5-1.2B-Instruct и RefalMachine/RuadaptQwen3-4B-Instruct.

Также я решил использовать 2 промта:

```
prompt = f"Вопрос: {q}\n\nКонтекст:\n{s}\n\nОтвет одним словом:"
```

```
prompt = f"Вопрос: {q}\n\nпо этому вопросу найдены документы, в которых есть ответ:\n{s}\n\n Можешь подумать и запиши в конце ответ одним словом:"
```

Результаты:

Liquid

1: 7\10 (отвечал не 1 словом)

2: 4\10 (Из-за того, что на 1 промте он не отвечал 1 словом, я решил поменять промт для лучших результатов, но Коэффициент поражения поражает воображение, Попытка исправить - усугубила положение..)

Qwen

1: 7\10

2: 7\10

Выводы:

Хотелось сказать, что обе модели справились нормально, но второй промт наклоняет чашу весов с Qwen. Также просмотрев релевантные документы, можно сделать вывод, что наша RAG система работает правильно и выдает подходящий контекст.