


ИНТЕЛЛЕКТ ➤

Pretraining, continuous pretraining, данные

к.ф.-м.н. Тихомиров Михаил Михайлович

старший научный сотрудник
НИВЦ МГУ имени М. В. Ломоносова

Pretraining LLM



Обучение/дообучение LLM - процедура изменения весов нейронной сети с целью минимизации некоторой функции потерь.

- **Pretraining (предобучение)**- этап обучения нейросети на огромном количестве данных, которые могут быть получены “без разметки”, на подходящей задаче, например, языковое моделирование
- **Fine-tuning (тонкая настройка)**- этап дообучения нейросети на размеченных данных по конкретной задаче
- **Continuous pre-training (продолженное предобучение)** - по сути этап предобучения, применяемый уже к обученным моделям (после pre-training)
- **Post-training (пост-обучение)** - этап обучения современных LLM после pretraining (аналог fine-tuning), в котором закладываются навыки “ИИ-ассистента”

Обучение задаче языкового моделирования



Московский
государственный
университет
имени М.В. Ломоносова

На вход в модель подаются 3 составляющие:

- **input_ids** (то, что получается после токенизации)
- **attention_mask** (1 на позициях, которые нам нужны, 0 на позициях, которые нам не интересны)
- **labels** (по сути копия от input_ids, которая будет сдвинута на 1 шаг в дальнейшем)

И затем модель обучается минимизировать cross entropy loss

$$L = - \sum_{k=1}^K y_k \log(p_k)$$

GPT vs FLOPS: сколько стоит GPT




Model	Total train compute (PF-days)	Total train compute (flops)	Params (M)	Training tokens (billions)	Flops per param per token	Mult for bwd pass
BERT-Base	1.89E+00	1.64E+20	109	250	6	3
BERT-Large	6.16E+00	5.33E+20	355	250	6	3
RoBERTa-Base	1.74E+01	1.50E+21	125	2,000	6	3
RoBERTa-Large	4.93E+01	4.26E+21	355	2,000	6	3
GPT-3 Small	2.60E+00	2.25E+20	125	300	6	3
GPT-3 Medium	7.42E+00	6.41E+20	356	300	6	3
GPT-3 Large	1.58E+01	1.37E+21	760	300	6	3
GPT-3 XL	2.75E+01	2.38E+21	1,320	300	6	3
GPT-3 2.7B	5.52E+01	4.77E+21	2,650	300	6	3
GPT-3 6.7B	1.39E+02	1.20E+22	6,660	300	6	3
GPT-3 13B	2.68E+02	2.31E+22	12,850	300	6	3
GPT-3 175B	3.64E+03	3.14E+23	174,600	300	6	3

Для обучения GPT-3 175B (**3640 PF-days**, **\$4.6M-\$12M**) потребовалось бы **7 месяцев** обучения на **512 V100**, или **43 дня** на **512 A100** (**Р70М** и **112 месяцев на Volta-1**).

Стоимость обучения InstructGPT: **4.9 PF-days** для **SFT** и **60 PF-days** для **PPO-ptx**.

Сколько стоит LLaMa-3.1-405B



- Обучение модели стоило 3.8×10^{25} FLOPs или 38 иоттафлопс.
- Использовался кластер из 16000 H100
- В 100 раз “дороже”, чем GPT-3 175B

Training Costs	Pre-Training	Context Extension	Post-Training	Total
in H800 GPU Hours	2664K	119K	5K	2788K
in USD	\$5.328M	\$0.238M	\$0.01M	\$5.576M

Table 1 | Training costs of DeepSeek-V3, assuming the rental price of H800 is \$2 per GPU hour.

- Модель от китайских производителей, **671B** параметров (37B активных)
- Использовался кластер из **2048 H800, 2.8M GPU часов (~ 60 дней)**.
- **Корпус из 14.8T токенов**
- Обучение полностью в FP8! (впервые). Доступно только на H100 серии.

Scaling Law



$$L(N, D) = \frac{A}{N^\alpha} + \frac{B}{D^\beta} + E$$

L - loss

N - количество параметров модели

D - количество токенов в корпусе

E - неуменьшаемый компонент

Scaling Law



$$L(N, D) = \underbrace{\frac{406.4}{N^{0.34}}}_{\text{finite model}} + \underbrace{\frac{410.7}{D^{0.28}}}_{\text{finite data}} + \underbrace{1.69}_{\text{irreducible}}$$

- На примере определенного датасета среднего качества
- Важность данных = Важность размера модели!!!

Scaling Law



Parameters	Approach 2		Approach 3	
	FLOPs	Tokens	FLOPs	Tokens
400 Million	1.84e+19	7.7 Billion	2.21e+19	9.2 Billion
1 Billion	1.20e+20	20.0 Billion	1.62e+20	27.1 Billion
10 Billion	1.32e+22	219.5 Billion	2.46e+22	410.1 Billion
67 Billion	6.88e+23	1.7 Trillion	1.71e+24	4.1 Trillion
175 Billion	4.54e+24	4.3 Trillion	1.26e+24	12.0 Trillion
280 Billion	1.18e+25	7.1 Trillion	3.52e+25	20.1 Trillion
520 Billion	4.19e+25	13.4 Trillion	1.36e+26	43.5 Trillion
1 Trillion	1.59e+26	26.5 Trillion	5.65e+26	94.1 Trillion
10 Trillion	1.75e+28	292.0 Trillion	8.55e+28	1425.5 Trillion

Gopher - 280B, 300B

Chinchilla - 70B, 1.4T

Итоговый компьютер (flops)
одинаковый!

Task	Chinchilla	Gopher	Task	Chinchilla	Gopher
abstract_algebra	31.0	25.0	anatomy	70.4	56.3
astronomy	73.0	65.8	business_ethics	72.0	70.0
clinical_knowledge	75.1	67.2	college_biology	79.9	70.8
college_chemistry	51.0	45.0	college_computer_science	51.0	49.0
college_mathematics	32.0	37.0	college_medicine	66.5	60.1
college_physics	46.1	34.3	computer_security	76.0	65.0
conceptual_physics	67.2	49.4	econometrics	38.6	43.0
electrical_engineering	62.1	60.0	elementary_mathematics	41.5	33.6
formal_logic	33.3	35.7	global_facts	39.0	38.0
high_school_biology	80.3	71.3	high_school_chemistry	58.1	47.8
high_school_computer_science	58.0	54.0	high_school_european_history	78.8	72.1
high_school_geography	86.4	76.8	high_school_gov_and_politics	91.2	83.9
high_school_macroconomics	70.5	65.1	high_school_mathematics	31.9	23.7
high_school_microeconomics	77.7	66.4	high_school_physics	36.4	33.8
high_school_psychology	86.6	81.8	high_school_statistics	58.8	50.0
high_school_us_history	83.3	78.9	high_school_world_history	85.2	75.1
human_aging	77.6	66.4	human_sexuality	86.3	67.2
international_law	90.9	77.7	jurisprudence	79.6	71.3
logical_fallacies	80.4	72.4	machine_learning	41.1	41.1
management	82.5	77.7	marketing	89.7	83.3
medical_genetics	69.0	69.0	miscellaneous	84.5	75.7
moral_disputes	77.5	66.8	moral_scenarios	36.5	40.2
nutrition	77.1	69.9	philosophy	79.4	68.8
prehistory	81.2	67.6	professional_accounting	52.1	44.3
professional_law	56.5	44.5	professional_medicine	75.4	64.0
professional_psychology	75.7	68.1	public_relations	73.6	71.8
security_studies	75.9	64.9	sociology	91.0	84.1
us_foreign_policy	92.0	81.0	virology	53.6	47.0
world_religions	87.7	84.2			

Table A6 | **Chinchilla MMLU results.** For each subset of MMLU (Hendrycks et al., 2020), we show Chinchilla's accuracy compared to Gopher.

Pretraining - это не просто скормить что-то в языковую модель




С первого взгляда сама процедура простая, данные идут на вход, минимизируем loss, GPT на выходе?

1. Качество данных оказывает ключевую роль:
Garbage in - garbage out
2. Сама процедура также может быть разбита на последовательность шагов с разными данными и разными гиперпараметрами
3. **Запустить** стабильное **обучение** языковой модели и получить что-то **полезное на выходе** - это всё ещё **вызов** для всех, кроме некоторых компаний в мире.


MiniCPM подход: два этапа обучения





Data Mixture of Stable Stage



Data Mixture of Decay Stage




MiniCPM подход: annealing phase



$$lr(s) = \begin{cases} \frac{s}{W} * \eta, & s < W \\ \eta, & W < s < S \\ f(s - S) * \eta, & S < s < S + D \end{cases}$$

Textbooks Are All You Need (Phi-1)



The Stack - filtered code-language dataset (6B токенов)

CodeTextbook - synthetic textbook (1B т., генерировали через GPT-3.5)

Code Exercises - также синтетика, но instruct (~180M токенов)

Phi-3: развитие идеи Phi-1




- Наращивание масштабов
- 4.5T токенов
- Смешивание синтетики + Web дата (качественных)

	Phi-3-mini 3.8b	Phi-3-small 7b	Phi-3-medium 14b	Phi-2 2.7b	Mistral 7b	Gemma 7b	Llama-3-In 8b	Mixtral 8x7b	GPT-3.5 version 1106
MMLU (5-Shot) [HBK*21a]	68.8	75.7	78.0	56.3	61.7	63.6	66.5	70.5	71.4
HellaSwag (5-Shot) [ZHH*19]	76.7	77.0	82.4	53.6	58.5	49.8	71.1	70.4	78.8
ANLI (7-Shot) [NWD*20]	52.8	58.1	55.8	42.5	47.1	48.7	57.3	55.2	58.1
GSM-8K (8-Shot, CoT) [CKB*21]	82.5	89.6	91.0	61.1	46.4	59.8	77.4	64.7	78.1
MATH (0-Shot, CoT) [HBK*21a]	41.3	34.6	53.1	—	15.0	13.6	28.2	11.1	45.3
MedQA (2-Shot) [FPO*20]	53.8	65.4	69.9	40.9	50.0	49.6	60.5	62.2	63.4
AGIEval (0-Shot) [ZCG*23]	37.5	45.1	50.2	29.8	35.1	42.1	42.0	45.2	48.4
TriviaQA (5-Shot) [JCWZ17]	64.0	58.1	73.9	45.2	75.2	72.3	67.7	82.2	85.8
Arc-C (10-Shot) [CCE*18]	84.9	90.7	91.6	75.9	78.6	78.3	82.8	87.3	87.4
Arc-E (10-Shot) [CCE*18]	94.6	97.0	97.7	88.5	90.6	91.4	93.4	95.6	96.3
PIQA (5-Shot) [BZGC19]	84.2	86.9	87.9	60.2	77.7	78.1	75.7	86.0	86.6
SociQA (5-Shot) [BZGC19]	76.6	79.2	80.2	68.3	74.6	65.5	73.9	75.9	68.3
BigBench-Hard (3-Shot, CoT) [SRH*22, SSS*22]	71.7	79.1	81.4	59.4	57.3	59.6	51.5	69.7	68.32
WinoGrande (5-Shot) [SLBBC19]	70.8	81.5	81.5	54.7	54.2	55.6	65.0	62.0	68.8
OpenBookQA (10-Shot) [MCKS18]	83.2	88.0	87.4	73.6	79.8	78.6	82.6	85.8	86.0
BoolQ (2-Shot) [CLC*19]	77.2	84.8	86.5	—	72.2	66.0	80.9	77.6	79.1
CommonSenseQA (10-Shot) [THLB19]	80.2	80.0	82.8	69.3	72.6	76.2	79.0	78.1	79.6
TruthfulQA (10-Shot, MC2) [LJBE22]	65.0	70.2	75.1	—	53.0	52.1	63.2	60.1	85.8
HumanEval (0-Shot) [CTJ*21]	58.5	61.0	62.2	59.0	28.0	34.1	60.4	37.8	62.2
MBPP (3-Shot) [AON*21]	70.0	71.7	75.2	60.6	50.8	51.5	67.7	60.2	77.8
Average	69.7	73.6	76.7	—	58.9	59.3	67.3	66.8	72.8
GPQA (2-Shot, CoT) [BHS*23]	32.8	34.3	—	—	—	—	—	—	29.0
MT Bench (2 round ave.) [ZCS*23]	8.38	8.70	8.91	—	—	—	—	—	8.35

Phi-1-2-3 некоторые выводы



- Первые две версии обвиняли в train on test
- 3 версия вышла хорошей
 - По метрикам обходит всех в своей “весовой”
- Секрет успеха: комбинация синтетики и настоящих данных, но в итоге 3 версия обучалась на 4.5T токенах
- Качество данных существенно!



Continuous pretraining



- **Адаптация на язык**
 - Часто с сопутствующим расширением токенайзера
 - Требуется большой корпус текстов на целевом языке
 - Часто качество на других языках падает
- **Адаптация на предметную область**
 - Вместо одной модели, которая знает все, много моделей-экспертов по каждому из доменов
 - Требуется корпус текстов из целевой предметной области
- **Адаптация на класс задач**




- Главная проблема - катастрофическая забывчивость!
- Полезно при возможности доливать часть исходного корпуса в данные для CPT
- Больше вопросов, чем ответов:
 - full tune? LoRa? embeddings?
 - если LoRa то какие ранги, все ли слои одинаково важны?
 - кастомные веса для функции потерь на “новых” токенах?
 - Гиперпараметры? (weight decay, learning rate, batch size)



EFFICIENT AND EFFECTIVE TEXT ENCODING FOR CHINESE LLAMA AND ALPACA

Одна из первых статей по адаптации LLM в пост-Llama эру

- Адаптация на китайский язык
- Расширение токенайзера иероглифами
- 20 и 120 ГБ данных



Chinese LLaMa: гиперпараметры



Settings	7B	Plus-7B	13B	Plus-13B	33B
Training data	20 GB	120 GB	20 GB	120 GB	20 GB
Batch size	1,024	2,304	2,304	2,304	2,304
Peak learning rate	2e-4/1e-4	2e-4	2e-4	2e-4	2e-4
Max sequence length	512	512	512	512	512
LoRA rank	-/8	8	8	8	8
LoRA alpha	-/32	32	32	32	32
LoRA weights	-/QKVO	QKVO, MLP	QKVO, MLP	QKVO, MLP	QKVO, MLP
Trainable params (%)	2.97%/6.06%	6.22%	4.10%	4.10%	2.21%

embeddings + lm_head тоже тренируются!

Chinese LLaMa: результаты на китайском



Московский
государственный
университет
имени М.В. Ломоносова

Model	Valid Set		Test Set	
	Zero-shot	5-shot	Zero-shot	5-shot
<i>Random</i>	25.0	25.0	25.0	25.0
LLaMA-65B	37.2	41.2	33.4	38.8
LLaMA-33B	34.5	37.9	32.4	36.0
LLaMA-13B	27.8	30.9	28.5	29.6
LLaMA-7B	25.6	25.3	26.7	27.8
Chinese-LLaMA-33B	34.9	38.4	34.6	39.5
Chinese-LLaMA-Plus-13B	27.3	34.0	27.8	33.3
Chinese-LLaMA-13B	29.4	35.0	29.2	33.7
Chinese-LLaMA-Plus-7B	27.3	28.3	26.8	28.4
Chinese-LLaMA-7B	26.2	26.2	27.1	27.2
Chinese-Alpaca-33B	43.3	42.6	41.6	40.4
Chinese-Alpaca-Plus-13B	43.3	42.4	41.5	39.9
Chinese-Alpaca-13B	37.1	36.3	36.7	34.5
Chinese-Alpaca-Plus-7B	36.7	32.9	36.4	32.3
Chinese-Alpaca-7B	30.8	32.5	30.7	29.2

RETHINKING LLM LANGUAGE ADAPTATION: A CASE STUDY ON CHINESE MIXTRAL



Московский
государственный
университет
имени М.В. Ломоносова

- Продолжение работы про адаптацию LLaMa от тех же авторов
- Адаптировали mixtral
- Показали метрики не только на китайском

Chinese Mixtral: гиперпараметры



Settings	Chinese-Mixtral	Chinese-Mixtral-Instruct
Trained From	Mixtral-8x7B-v0.1	Chinese-Mixtral
Training Data	20GB raw text ($\approx 7B$ tokens)	5M Instruction SFT
Training Epochs	1	3
Layer #	32	
Total Experts #	8	
Used Experts #	2	
Hidden Size	4096	
Context Length	32768	
Vocab Size	32000	
Training Method	QLoRA + Full training on embedding and LM head	
LoRA Rank	64	
LoRA Alpha	128	
LoRA Applied to	QKVO + W123 + Gate	

Chinese Mixtral: результаты на китайском



Московский
государственный
университет
имени М.В. Ломоносова

Table 2: Results on C-Eval.

Model	Valid Set		Test Set	
	zero-shot	5-shot	zero-shot	5-shot
Chinese-LLaMA-2-13B	40.6	42.7	38.0	41.6
Chinese-Alpaca-2-13B	44.3	45.9	42.6	44.0
Mixtral-8x7B-v0.1	47.3	54.6	46.1	50.3
Mixtral-8x7B-Instruct-v0.1	51.6	54.0	48.7	50.7
Chinese-Mixtral	45.8	54.2	43.1	49.1
Chinese-Mixtral-Instruct	51.7	55.0	50.0	51.5

Chinese Mixtral: результаты на английском



Московский
государственный
университет
имени М.В. Ломоносова

Table 4: Results on Open LLM Leaderboard. HellaS: HellaSwag, TQA: TruthfulQA, WinoG: WinoGrande.

Model	ARC	HellaS	MMLU	TQA	WinoG	GSM8K	Average
Chinese-LLaMA-2-13B	55.80	79.53	53.01	38.24	75.69	3.94	51.04
Chinese-Alpaca-2-13B	58.70	79.76	55.12	50.22	75.61	25.02	57.41
Mixtral-8x7B-v0.1	66.38	86.46	71.88	46.81	81.69	57.62	68.47
Mixtral-8x7B-Instruct-v0.1	70.14	87.55	71.40	64.98	81.06	61.11	72.70
Chinese-Mixtral	67.58	85.34	70.38	46.86	82.00	0.00	58.69
Chinese-Mixtral-Instruct	67.75	85.67	71.53	57.46	83.11	55.65	70.19

Continual Pre-Training for Cross-Lingual LLM Adaptation: Enhancing Japanese Language Capabilities



Московский
государственный
университет
имени М.В. Ломоносова


- 100 миллиардов токенов
- Полный тюнинг!
- Также расширяли токенайзер

Params	d_{model}	# Heads	# Layers	Context length	GQA	# Tokens	LR
7B	4096	32	32	4096	×	100B	1.0×10^{-4}
13B	5120	40	40	4096	×	100B	1.0×10^{-4}
70B	8192	64	80	4096	✓	100B	5.0×10^{-5}


Результаты



Japanese tasks



English tasks



Зависимость от количества токенов и влияние расширения




Figure 6: Performance curve of Swallow-VE and Swallow in automatic summarization (XL-Sum).





Figure 7: Performance curve of Swallow-VE and Swallow in the average score of question answering task (JCQA, JEMHQA, NIILC).

Improving Language Plasticity via Pretraining with Active Forgetting




Московский
государственный
университет
имени М.В. Ломоносова

- 1. Pretrain:** претрейн модели на англ языке
- 2. Language Adapt:** обучаем только эмбеддинги на целевом языке
- 3. Task Adapt:** обучаем только тело трансформера на целевой задаче
- 4. Assemble:** совмещаем модель из 2 и 3 -> получаем модель для конкретной задачи и на конкретном языке



Active Forgetting



Method	vi	sw	es	bg	de	fr	el	ru
Standard	65.8	55.6	68.0	65.5	62.2	63.5	63.1	56.9
Forgetting	62.8	59.5	74.0	71.7	68.5	71.2	70.8	65.8
Relative Gain	−4.6%	+7.0%	+8.8%	+9.5%	+10.1%	+12.1%	+12.2%	+15.6%

Table 1: Accuracy comparison of forgetting and standard PLMs on XNLI (table continues).

Method	zh	ur	hi	tr	ar	th	Avg	en
Standard	53.2	36.8	39.7	38.9	41.2	35.3	53.3	86.1
Forgetting	63.5	45.8	52.9	52.7	59.5	59.7	62.7	85.1
Relative Gain	+19.4%	+24.5%	+33.2%	+35.5%	+44.4%	+69.1%	+21.2%	−1.2%


Table 2: Accuracy comparison of forgetting and standard PLMs on XNLI (table continued). On average, forgetting PLMs achieve a 21.2% relative gain in accuracy compared to standard PLMs across the languages tested, where averaged relative gain = $\frac{\sum_{x \in \{\text{languages}\}} \text{Relative Gain of } x}{\#\text{Languages}}$.

- Модели на основе **Qwen3 32B** и **8B**
- Произвели **замену токенизации** (в отличие от прошлых версий)!
- Наличие **роста метрик** качества (в частности MMLU!)
- Вместо Continuous pretraining идет “**General Post-Training**” этап на **40 миллиардах** токенах **инструктивных** данных
- Упор на **качественный post-training** пайплайн (особенно к **версии 2.1**)


T-pro 2.0: токенайзер




Московский
государственный
университет
имени М.В. Ломоносова




(a) T-pro



(b) Qwen3



(c) Ruadapt-Qwen3



(d) GigaChat

T-pro 2.0: loss curve




Figure 3: Midtraining training loss as a function of optimization steps. Loss drops steeply during the first $\sim 1\text{k}$ steps ($\sim 4\text{B}$ tokens) and then gradually plateaus, indicating that most adaptation to the new tokenizer happens early in the run.

T-pro 2.0: метрики



Model	MERA	MaMuRAMu	ruMMLU-Pro	Arena Hard Ru	WildChat Hard Ru	Arena Hard 2 HP	Arena Hard 2 CW
<i>Open Source Models (27B-32B class)</i>							
T-pro 2.0 (Ours)	0.66	0.851	0.697	91.1 / 90.36	72.6 / 76.4	53.5 / 46.2	64.2 / 62.8
Qwen3-32B	0.582	0.833	0.677	83.95 / 84.66	59.6 / 51.9	46.4 / 32.9	53.7 / 41.5
RuadaptQwen3-32B-Instruct ¹	0.574	0.823	0.652	68.4 / 64.76	41.5 / 39.4	13 / 14.2	19.4 / 12.7
Gemma 3 27B ²	0.577	0.808	0.665	82.66	58.4	23.5	74.7
DeepSeek-R1-Distill-Qwen-32B ³	0.508	0.787	0.537	34.07 / 22.83	12.1 / 8.7	7.2 / 7.2	5.9 / 3.5
<i>Open Source Larger Scale & Proprietary Models</i>							
DeepSeek-V3	0.677	0.875	0.736	92.67	66.8	45.8	59.9
DeepSeek-R1 ³	—	—	—	95.74	90.3	73.6	90.3
YandexGPT5-Pro ⁴	—	—	0.604	19.13	12.1	3.8	2.6
GigaChat 2 Max ⁵	0.67	0.864	0.649	61.44	10.1	8.5	27.1
o4-mini ⁶ (medium)	—	—	—	95.63	74.4	67	49.8
GPT-4o ⁷	0.642	0.874	0.714	85.14	41.4	20.0	44.2

Model	T-Math	ruAIME 2024	ruAIME 2025	ruMATH-500	ruGPQA Diamond	ruLCB	Vikhr Math	Vikhr Physics
<i>Open Source Models (27B-32B class)</i>								
T-pro 2.0 (Ours)	0.541	0.704	0.646	0.94	0.591	0.563	0.799	0.51
Qwen3-32B	0.529	0.706	0.625	0.938	0.606	0.537	0.809	0.531
RuadaptQwen3-32B-Instruct	0.444	0.575	0.450	0.450	0.591	0.500	0.528	0.337
Gemma 3 27B	0.208	0.248	0.231	0.860	0.439	0.261	0.548	0.276
DeepSeek-R1-Distill-Qwen-32B	0.254	0.510	0.402	0.898	0.631	0.493	0.462	0.286
<i>Open Source Larger Scale & Proprietary Models</i>								
DeepSeek-V3	0.278	0.319	0.285	0.882	0.657	0.444	0.613	0.367
DeepSeek-R1	0.619	0.800	0.800	0.972	0.763	0.69	0.864	0.469
YandexGPT5-Pro	0.13	0.062	0.046	0.682	0.354	0.265	0.372	0.252
GigaChat 2 Max	0.142	0.102	0.062	0.702	0.475	0.272	0.372	0.245
o4-mini (medium)	0.634	0.781	0.771	0.958	0.773	0.705	0.834	0.408
GPT-4o	0.106	0.090	0.069	0.766	0.510	0.131	0.372	0.296

Ruadapt: вычислительно эффективно адаптируем с минимальными потерями



Этап 1: Новая русская токенизация

Русскоязычный
корпус (текст)



Обучение нового
токенизатора

Новый русский
токенизатор



Этап 2: Адаптация базовой модели

Исходная базовая LLM
(США/Китай/иное)



Новый русский
токенизатор

Адаптация модели
для русскоязычных
текстов

Адаптированная
базовая LLM (РФ)



Этап 3: LEP и калибровка инструкций

Адаптированная
базовая LLM (РФ)

LEP метод:
Проекция знаний в
инструктивную
модель
(Learned Embedding
Propagation)


Спроецированная
инструктивная
LLM (РФ)

Финальная
калибровка с
инструктивными
данными
(Русский язык)

Готовая Ruadapt
инструктивная
LLM (РФ)



Одиночный длинный запрос



18 миллиардов токенов для адаптации базовой модели

Ruadapt: метрики на бенчмарке llmtf



Model	Mean	Total Time (s)	IFEval	Knowledge	Long	RAG	Skills
Qwen3.5-27B (2xGPU)	0.718 $\pm$ 0.004	30181	0.815 $\pm$ 0.017	0.733 $\pm$ 0.006	0.631 $\pm$ 0.010	0.866	0.503 $\pm$ 0.004
Qwen3.5-35B-A3B (2xGPU)	0.701 $\pm$ 0.003	12519	0.823 $\pm$ 0.011	0.742 $\pm$ 0.005	0.599 $\pm$ 0.006	0.868	0.470 $\pm$ 0.004
T-pro-it-2.1	0.691 $\pm$ 0.003	66586	0.805 $\pm$ 0.013	0.708 $\pm$ 0.005	0.620 $\pm$ 0.006	0.870	0.454 $\pm$ 0.004
Qwen3-32B	0.682 $\pm$ 0.003	74544	0.797 $\pm$ 0.012	0.682 $\pm$ 0.005	0.611 $\pm$ 0.005	0.875	0.446 $\pm$ 0.004
<u>RuadaptQwen3-32B-Instruct</u>	0.671 $\pm$ 0.003	53852	0.751 $\pm$ 0.013	0.676 $\pm$ 0.005	0.629 $\pm$ 0.006	0.872	0.428 $\pm$ 0.004
Qwen3-14B	0.670 $\pm$ 0.003	32618	0.815 $\pm$ 0.011	0.641 $\pm$ 0.006	0.603 $\pm$ 0.006	0.868	0.422 $\pm$ 0.004
Qwen3-30B-A3B-Instruct-2507	0.669 $\pm$ 0.003	21103	0.786 $\pm$ 0.013	0.676 $\pm$ 0.006	0.591 $\pm$ 0.005	0.860	0.433 $\pm$ 0.004
T-lite-it-2.1	0.657 $\pm$ 0.003	15364	0.795 $\pm$ 0.013	0.631 $\pm$ 0.005	0.607 $\pm$ 0.005	0.843	0.410 $\pm$ 0.004
T-pro-it-2.0	0.650 $\pm$ 0.003	59405	0.672 $\pm$ 0.012	0.697 $\pm$ 0.005	0.618 $\pm$ 0.005	0.878	0.386 $\pm$ 0.004
Qwen3-8B	0.642 $\pm$ 0.003	20459	0.783 $\pm$ 0.011	0.596 $\pm$ 0.005	0.572 $\pm$ 0.005	0.843	0.413 $\pm$ 0.004
YandexGPT-5-Lite-8B-instruct	0.633 $\pm$ 0.003	23602	0.714 $\pm$ 0.013	0.655 $\pm$ 0.005	0.540 $\pm$ 0.006	0.858	0.396 $\pm$ 0.004
Qwen3-4B-Instruct	0.622 $\pm$ 0.003	14998	0.783 $\pm$ 0.014	0.567 $\pm$ 0.005	0.541 $\pm$ 0.005	0.828	0.392 $\pm$ 0.004
<u>RuadaptQwen3-8B-Hybrid</u>	0.622 $\pm$ 0.003	15171	0.746 $\pm$ 0.012	0.595 $\pm$ 0.005	0.563 $\pm$ 0.005	0.834	0.369 $\pm$ 0.004
<u>RuadaptQwen3-4B-Instruct</u>	0.613 $\pm$ 0.003	11270	0.751 $\pm$ 0.013	0.574 $\pm$ 0.005	0.565 $\pm$ 0.005	0.827	0.347 $\pm$ 0.004
Qwen3-4B	0.604 $\pm$ 0.003	15003	0.744 $\pm$ 0.013	0.551 $\pm$ 0.005	0.526 $\pm$ 0.006	0.826	0.375 $\pm$ 0.004
avibe	0.603 $\pm$ 0.004	15251	0.604 $\pm$ 0.016	0.632 $\pm$ 0.005	0.547 $\pm$ 0.005	0.847	0.387 $\pm$ 0.004
GigaChat3-10B-A1.8B-bf16	0.595 $\pm$ 0.004	12987	0.554 $\pm$ 0.018	0.645 $\pm$ 0.005	0.567 $\pm$ 0.005	0.857	0.353 $\pm$ 0.004
T-lite-it-1.0	0.581 $\pm$ 0.004	18474	0.579 $\pm$ 0.016	0.621 $\pm$ 0.005	0.533 $\pm$ 0.006	0.844	0.328 $\pm$ 0.003
Vikhr-Nemo-12B-Instruct-R-21-09-24	0.569 $\pm$ 0.004	25495	0.544 $\pm$ 0.016	0.558 $\pm$ 0.005	0.535 $\pm$ 0.005	0.862	0.344 $\pm$ 0.004
RuadaptQwen2.5-7B-Lite-Beta	0.557 $\pm$ 0.003	13696	0.514 $\pm$ 0.015	0.605 $\pm$ 0.005	0.528 $\pm$ 0.006	0.841	0.297 $\pm$ 0.004

Ruadapt: метрики на llm as a judge арене



Model	Elo Rating	STD	95% CI	Median Length (chars)
T-pro-it-2.0	1588	22	[1552, 1635]	2256
Qwen3-235B-A22B-Instruct-2507	1519	9	[1500, 1537]	1858
T-pro-it-2.1	1486	20	[1450, 1531]	1811
Qwen3.5-27B	1474	20	[1438, 1512]	2134
Qwen3.5-35B-A3B	1442	18	[1412, 1479]	2149
Qwen3-30B-A3B-Instruct-2507	1429	19	[1391, 1465]	2152
T-lite-it-2.1	1396	18	[1362, 1429]	1978
Qwen3-32B	1261	14	[1236, 1288]	1551
RuadaptQwen3-32B-Instruct	1235	15	[1209, 1271]	1646
Qwen3-4B-Instruct-2507	1228	15	[1200, 1258]	2267
Qwen3-14B	1201	16	[1168, 1232]	1624
RuadaptQwen3-4B-Instruct	1176	15	[1153, 1207]	1979
avibe	1175	13	[1149, 1198]	1728
RuadaptQwen3-8B-Hybrid	1173	13	[1148, 1200]	1492
Qwen3-8B	1147	16	[1115, 1171]	1729
RuadaptQwen2.5-7B-Lite-Beta	1083	14	[1062, 1113]	1252
gpt-4-1106-preview	1030	9	[1013, 1046]	1261
Qwen3-4B	1001	15	[972, 1028]	1636
T-lite-it-1.0	1000	16	[980, 1038]	1407
gpt-4o-mini	1000	0	[1000, 1000]	876
GigaChat3-10B-A1.8B-bf16	961	15	[931, 987]	959
Vikhr-Nemo-12B-Instruct-R-21-09-24	932	14	[909, 962]	1540
YandexGPT-5-Lite-8B-instruct	794	21	[752, 835]	636

Источники данных

Откуда берут данные?



- Wikipedia
- Новости
- Reddit / Pikabu / иные платформы
- Книги, учебники
- Web (основной)
- GitHub
- StackOverflow
- Видео? OCR?

Common Crawl



Московский
государственный
университет
имени М.В. Ломоносова

- 20 TB каждый месяц
- “Грязные” данные
- Настоящих текстов в реальности сильно меньше
- Основа большинства датасетов

Distribution of Languages

The language of a document is identified by [Compact Language Detector 2 \(CLD2\)](#). It is able to identify 160 different languages and up to 3 languages per document. The table lists the percentage covered by the primary language of a document (returned first by CLD2). So far, only HTML pages are passed to the language detector. The underlying data including page counts is provided in [languages.csv](#).

crawl	CC-MAIN-2024-33	CC-MAIN-2024-38	CC-MAIN-2024-42
language ↕	%	%	%
eng	43.1787	44.1210	43.4241
rus	6.2242	6.1556	6.0444
zho	5.1917	4.6266	4.8129
deu	5.0895	5.4471	5.3038
jpn	4.8790	5.1119	5.0419
spa	4.5819	4.4769	4.5387
fra	4.2439	4.4292	4.3960
<unknown>	3.2930	2.6706	3.2780
ita	2.4921	2.5224	2.5282
por	2.2179	2.2141	2.3146
pol	1.9342	1.8868	1.8065
nld	1.7821	1.9149	1.8145
tur	1.2744	1.2328	1.2422
ind	1.1139	1.0532	1.1235
vie	1.0514	1.0332	1.0454
ces	1.0158	1.1019	1.0630

C4 (Colossal Clean Crawled Corpus)



“Очищенный” Common Crawl, представлен в работе про T5

- Оставляли только строки, которые заканчиваются на .?!..
- Предложения минимум из 5 слов, страницы минимум из 3 предложений
- Удалили “нецензурные” тексты (по словарю)
- Удалили все повторы по три предложения
- Оставили только английский!
- Оставили 750-800GB

The Pile



Московский
государственный
университет
имени М.В. Ломоносова

Component	Raw Size	Weight	Epochs	Effective Size	Mean Document Size
Pile-CC	227.12 GiB	18.11%	1.0	227.12 GiB	4.33 KiB
PubMed Central	90.27 GiB	14.40%	2.0	180.55 GiB	30.55 KiB
Books3 [†]	100.96 GiB	12.07%	1.5	151.44 GiB	538.36 KiB
OpenWebText2	62.77 GiB	10.01%	2.0	125.54 GiB	3.85 KiB
ArXiv	56.21 GiB	8.96%	2.0	112.42 GiB	46.61 KiB
Github	95.16 GiB	7.59%	1.0	95.16 GiB	5.25 KiB
FreeLaw	51.15 GiB	6.12%	1.5	76.73 GiB	15.06 KiB
Stack Exchange	32.20 GiB	5.13%	2.0	64.39 GiB	2.16 KiB
USPTO Backgrounds	22.90 GiB	3.65%	2.0	45.81 GiB	4.08 KiB
PubMed Abstracts	19.26 GiB	3.07%	2.0	38.53 GiB	1.30 KiB
Gutenberg (PG-19) [†]	10.88 GiB	2.17%	2.5	27.19 GiB	398.73 KiB
OpenSubtitles [†]	12.98 GiB	1.55%	1.5	19.47 GiB	30.48 KiB
Wikipedia (en) [†]	6.38 GiB	1.53%	3.0	19.13 GiB	1.11 KiB
DM Mathematics [†]	7.75 GiB	1.24%	2.0	15.49 GiB	8.00 KiB
Ubuntu IRC	5.52 GiB	0.88%	2.0	11.03 GiB	545.48 KiB
BookCorpus2	6.30 GiB	0.75%	1.5	9.45 GiB	369.87 KiB
EuroParl [†]	4.59 GiB	0.73%	2.0	9.17 GiB	68.87 KiB
HackerNews	3.90 GiB	0.62%	2.0	7.80 GiB	4.92 KiB
YoutubeSubtitles	3.73 GiB	0.60%	2.0	7.47 GiB	22.55 KiB
PhilPapers	2.38 GiB	0.38%	2.0	4.76 GiB	73.37 KiB
NIH ExPorter	1.89 GiB	0.30%	2.0	3.79 GiB	2.11 KiB
Enron Emails [†]	0.88 GiB	0.14%	2.0	1.76 GiB	1.78 KiB
The Pile	825.18 GiB			1254.20 GiB	5.91 KiB

Composition of the Pile by Category

■ Academic ■ Internet ■ Prose ■ Dialogue ■ Misc





Figure 1: Treemap of Pile components by effective size.

The Pile




- Разнообразный по доменам датасет
- Опять английский язык основной
- ~800GB
- Отдельные методы фильтрации и чистки в зависимости от домена

- От Huggingface
- На базе Common Crawl
- 15T токенов, 44 TB на диске
- English
- Есть версия fineweb-edu - качественных образовательных данных (1.3T токенов)



- Фокус на мультязыз
- Обработка 96 дампов Common Crawl за 2013-2024 года
- Проведена дедупликация, фильтрация и тп
- 100+ языков (заявлено про 10000)
- 20 ТБ текстов



fineweb-2: языки



Московский
государственный
университет
имени М.В. Ломоносова

ISO 639-3 code	Script	Name	Language Family	Subset	Words	Documents	UTF-8 Bytes	Disk size
rus	Cyrl	Russian	Indo-European	rus_Cyrl	588,579,493,780	699,083,579	5.82TB	1.81TB
cmn	Hani	Mandarin Chinese	Sino-Tibetan	cmn_Hani	543,543,038,750	636,058,984	2.42TB	1.48TB
deu	Latn	German	Indo-European	deu_Latn	262,271,052,199	495,964,485	1.51TB	719.08GB
jpn	Jpan	Japanese	Japonic	jpn_Jpan	331,144,301,801	400,138,563	1.50TB	667.44GB
spa	Latn	Spanish	Indo-European	spa_Latn	261,523,749,595	441,287,261	1.32TB	593.82GB
fra	Latn	French	Indo-European	fra_Latn	220,662,584,640	360,058,973	1.11TB	502.82GB
ita	Latn	Italian	Indo-European	ita_Latn	139,116,026,491	238,984,437	739.24GB	332.47GB
por	Latn	Portuguese	Indo-European	por_Latn	109,536,087,117	199,737,979	569.24GB	256.92GB
pol	Latn	Polish	Indo-European	pol_Latn	73,119,437,217	151,966,724	432.01GB	210.35GB
nld	Latn	Dutch	Indo-European	nld_Latn	74,634,633,118	147,301,270	397.51GB	176.98GB
ind	Latn	Indonesian	Austronesian	ind_Latn	60,264,322,142	100,238,529	348.65GB	141.70GB
vie	Latn	Vietnamese	Austro-Asiatic	vie_Latn	50,886,874,358	61,064,248	319.83GB	121.19GB
fas	Arab	Persian	Indo-European	fas_Arab	39,705,799,658	58,843,652	304.62GB	95.33GB
arb	Arab	Standard Arabic	Afro-Asiatic	arb_Arab	32,812,858,120	61,977,525	293.59GB	98.69GB
tur	Latn	Turkish	Turkic	tur_Latn	41,933,799,420	95,129,129	284.52GB	125.53GB
tha	Thai	Thai	Kra-Dai	tha_Thai	24,662,748,945	35,897,202	278.68GB	69.91GB
ukr	Cyrl	Ukrainian	Indo-European	ukr_Cyrl	25,586,457,655	53,101,726	254.86GB	84.98GB
ell	Grek	Modern Greek (1453-)	Indo-European	ell_Grek	22,827,957,288	47,421,073	222.05GB	73.16GB
kor	Hang	Korean	Koreanic	kor_Hang	48,613,120,582	60,874,355	213.43GB	98.50GB

- Новости, Вики, Web
- 90GB
- Чистота / качество данных
неизвестны

Omnia Russica



About

Omnia Russica (*lat. all Russian*) is an open source corpus project, containing 33 billion words.

Omnia Russica is combining major Russian corpus sources within one pipeline

	Format	Morphology	Syntax	Size
Wikipedia	vertical	TreeTagger	None	0.5 G
Taiga	CoNLL-U	UDpipe	UDpipe	4.5 G
Araneum Russicum	vertical	TreeTagger	None	25 G
Common Crawl	Plain text	None	None	3 G

- 75 GB
- Разные домены
- Производилась некоторая чистка

Website	Char count (M)	Word count (M)
pikabu	14938	2161
lenta	1008	135
stihi	2994	393
stackoverflow	1073	228
habr	5112	753
taiga_fontanka	419	55
librusec	10149	1573
burly	2646	352
ods_tass	1908	255
wiki	3473	469
math	987	177

- Лицензия под очень большим вопросом
- Много ГБ данных
- Различные книги, как полезные, так и остальные
- Есть мета-данные

```
"title": datasets.Value("string"),  
"file_name": datasets.Value("string"),  
"annotation": datasets.Value("string"),  
"keywords": datasets.Value("string"),  
"date": datasets.Value("string"),  
"genre": datasets.Value("string"),  
"authors": datasets.Sequence(datasets.Value("string")),  
"lang": datasets.Value("string"),  
"src_lang": datasets.Value("string"),  
"translator": datasets.Value("string"),  
"isbn": datasets.Value("string"),  
"publisher": datasets.Value("string"),  
"city": datasets.Value("string"),  
"year": datasets.Value("string"),  
"book_name": datasets.Value("string"),  
"fancy_title": datasets.Value("string"),  
"epigraphs": datasets.Sequence(datasets.Value("string")),  
"sections": datasets.Sequence(datasets.Value("string")),
```

Фреймворк, аккумулирующий разные русский датасеты

corus.tar.gz

Test no status

Links to publicly available Russian corpora + code for loading and parsing. [20+ datasets, 350Gb+ of text.](#)

Препроцессинг данных



MassiveWeb: Content Filtering



Московский
государственный
университет
имени М.В. Ломоносова

Фильтрация очевидно не подходящих документов

- По языку
- По Safety (мат и др.)
- Некоторые ручные правила фильтрации

Content
Filtering

Фильтрация происходит только на основе информации о документе, можно хорошо параллелить.

MassiveWeb: Text Extraction



- Так как чаще всего на входе Web страницы, нужно извлекать контент.
- То есть нужно парсить HTML разметку, выделять общие паттерны и тп
- Достаточно мало информации про данный этап

Text
Extraction

2

MassiveWeb: Quality Filtering



- Большинство Web контента не создано для человека и соответственно для LLM не подходит
- Фильтруют:
 - Документы короче 50 и больше 100 т. слов
 - Средняя длина слова в документе вне диапазона от 3 до 10
 - Отношение количества символов к количеству слов > 0.1
 - Stop word filter
 - ...

Quality
Filtering

Что еще можно добавить

- Фильтрация документов по перплексии
 - Использование маленьких “LLM”
 - Использование классических N-gram LM!
 - Символьные
 - По словам
- Фильтрация документов на основе классификации некоторыми моделями
 - По качеству
 - По приемлемости контента
 - По домену

Quality
Filtering

MassiveWeb: Repetition Removal



Один из показателей данных плохого качества - большое количество повторений.

- Документы с большим количеством повторений внутри удаляются
- Альтернативно можно вырезать из текста слишком явные повторы.



Measurement	Threshold
Duplicate line fraction	0.30
Duplicate paragraph fraction	0.30
Duplicate line character fraction	0.20
Duplicate paragraph character fraction	0.20
Top 2-gram character fraction	0.20
Top 3-gram character fraction	0.18
Top 4-gram character fraction	0.16
Duplicate 5-gram character fraction	0.15
Duplicate 6-gram character fraction	0.14
Duplicate 7-gram character fraction	0.13
Duplicate 8-gram character fraction	0.12
Duplicate 9-gram character fraction	0.11
Duplicate 10-gram character fraction	0.10



MassiveWeb: Document Deduplication

- Крайне важный этап
- Существенный n -gram overlap - убираем
- MinHash algorithm для околodубликатов
 - 13-gramm
 - Jaccard sim
 - Аппроксимация
- Близость двух документов выше 0.8 - удаляем из них
- Игнорируем пунктуацию при расчете n -gram

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Document
Deduplication

MassiveWeb: Test-set Filtering



- Мы хотим верить loss на валидации
- Значит надо удалить из Train сета всё слишком близкое к Test-set
- По аналогии с Deduplication

**Test-set
Filtering**

- Некоторые процедуры можно делать in-domain, например, фильтрацию по перплексии
- Для фильтра по языку fasttext lid
- Upsampling и Downsampling
 - Все данные равны, но некоторые, равнее
- Формулы? Таблицы? Latex? ...
- Мультимодальные данные?
- Часто огромное количество работы - составление правил и выяснение трешхолдов для них
- В данные нужно смотреть! Garbage in - Garbage out.